



INFOTEC CENTRO DE INVESTIGACIÓN E
INNOVACIÓN EN TECNOLOGÍAS DE LA
INFORMACIÓN Y COMUNICACIÓN

DIRECCIÓN ADJUNTA DE INNOVACIÓN Y
CONOCIMIENTO
GERENCIA DE CAPITAL HUMANO
POSGRADOS

“Un enfoque para la detección y eliminación de artefactos en señales de electroencefalografía a través de técnicas de aprendizaje profundo”

TESIS

Que para obtener el grado de DOCTOR EN
CIENCIAS EN CIENCIA DE DATOS

Presenta:

Emmanuel de Jesús Velásquez Martínez

Asesor:

Miguel Ángel Porta García

Autorización de impresión

Autorización de impresión.

Agradecimientos

Agradecimientos.

Tabla de contenido

Resumen.....	1
Capítulo 1 Introducción	2
1.1 Antecedentes	2
1.2 Estado del arte.....	3
1.3 Planteamiento del problema.....	9
1.4 Justificación del problema de investigación	10
1.5 Preguntas de investigación.....	10
1.6 Objetivo general.....	11
1.7 Objetivos específicos	11
1.8 Hipótesis	11
1.9 Alcance	11
1.10 Contribuciones	12
1.11 Comparación de trabajos del estado del arte respecto a la propuesta de investigación	1
Capítulo 2 Naturaleza de señal electroencefalografía (EEG)	4
2.1 Fuentes de las señales biomédicas	4
2.2 Bases neurofisiológicas de la generación de señales EEG y la medición del EEG	5
2.3 ¿Cómo el EEG viaja desde el cerebro hasta el dispositivo de registro?	7
2.3.1 Dentro del cerebro.....	7
2.3.2 Del cerebro al electrodo	8
2.3.3 Fundamentos de EEG.....	9
2.3.4 Sistema 10-20.....	9
2.3.5 Características de las señales cerebrales	10
2.3.6 Tipos de artefactos en EEG.....	11
2.4 Aplicaciones de las señales de Electroencefalograma	20
2.5 Tipos de transformadas en análisis de señales	21
2.5.1 Transformada de Fourier.....	21
2.6 Aprendizaje profundo en procesamiento de señales	28
2.6.1 Introducción al aprendizaje profundo.	28
Capítulo 3 Método y propuesta de investigación.....	31
3.1 Modelo de investigación	31
3.2 Propuesta de investigación a realizar	31
3.3 Descripción de los datos	33
3.3.1 Razones para simular datos EEG para probar métodos análisis	33

3.3.2	Generación de datos sintéticos EEG	33
3.3.3	Simulación de proyección de EEG en el cuero cabelludo	36
3.3.4	Generación de datos sintéticos	39
3.3.5	Conjunto de datos.....	41
3.4	Métricas de rendimiento para la eliminación de artefactos en señales EEG sintéticas	43
3.4.1	Error Cuadrático Medio	44
3.4.2	Error Cuadrático Medio de la Raíz (RMSE).....	44
3.4.3	Error Cuadrático Medio Normalizado (NMSE).....	45
3.4.4	Error relativo	45
3.4.5	Relación señal a artefacto	45
3.4.6	Información mutua.....	46
3.4.7	Error Absoluto Medio	46
3.4.8	Coefficiente de Correlación de Pearson	46
3.1	Métricas de rendimiento para la eliminación de artefactos en señales EEG reales	47
3.2	Desarrollo del modelo de aprendizaje profundo	47
3.2.1	Diseño de la arquitectura del modelo.....	47
3.2.2	Configuración de hiperparámetros.....	47
3.2.3	Técnicas de regularización y optimización	47
3.3	Implementación de la Adaptación de Dominio.....	47
3.3.1	Definición de dominios fuente y objetivo.....	47
3.3.2	Estrategias de alineación de distribuciones.....	47
3.4	Procedimiento de Entrenamiento y Validación.....	47
3.4.1	División de datos.....	47
3.4.2	Métricas de rendimiento.....	47
3.5	Herramientas y Entornos de Desarrollo	48
3.5.1	Software y librerías utilizadas	48
3.5.2	Recursos computacionales	48
Capítulo 4	Resultados	48
4.1	Análisis de Rendimiento del Modelo.....	48
4.1.1	Precisión en eliminación de artefactos.....	48
4.1.2	Comparación con técnicas tradicionales	48
4.2	Evaluación de la Adaptación de Dominio.....	48
4.2.1	Rendimiento en dominios no vistos	48
4.2.2	Robustez del modelo ante variaciones	48
4.3	Visualización de Resultados	48
4.3.1	Señales antes y después del procesamiento	48

4.3.2	Mapas de activación y interpretabilidad del modelo.....	48
4.4	Estudios de Caso	48
4.4.1	Aplicaciones prácticas en entornos clínicos.....	48
Capítulo 5	Discusión.....	48
5.1	Interpretación de los Resultados	48
5.1.1	Implicaciones de los hallazgos.....	48
5.2	Ventajas del Enfoque Propuesto	48
5.2.1	Mejoras en precisión y generalización.....	48
5.3	Limitaciones del Estudio.....	48
5.3.1	Restricciones de datos y modelo	48
5.4	Sugerencias para Trabajos Futuros	48
5.4.1	Extensiones del modelo	48
5.4.2	Aplicaciones en otras señales biomédicas.....	48
Capítulo 6	Conclusiones	48
6.1	Resumen de Contribuciones.....	48
6.1.1	Logros alcanzados respecto a los objetivos	49
6.2	Impacto en el Campo de Estudio	49
6.2.1	Avances en procesamiento de señales EEG.....	49
6.3	Recomendaciones	49
Capítulo 7	Anexos	49
7.1	Detalles Técnicos Adicionales	49
7.2	Publicaciones Derivadas	49
Referencias.....		50
Anexos		54

Índice de figuras

Figura 1.1 Etapas de procesamiento de las EEG	10
Figura 2.1 Fuentes de señales biomedicas. Fuente (Hemanth, 2020).	4
Figura 2.2 Medición de dipolos radiales y tangenciales. Fuente: (Jackson & Bolger, 2014).	6
Figura 2.3 Disposición paralela y la actividad sincrónica que permite que la señal sea medida en el cuero cabelludo. Fuente: (Jackson & Bolger, 2014). a: Las señales negativas se sumaran y serán medibles en el cuero cabelludo. b: Las señales positivas y negativas se cancelaran entre sí en cuero cabelludo, por lo tanto no serán medibles. c: No surge un dipolo claro de la disposición aleatoria de las cargas positivas y negativas, por lo que no se medirá ninguna señal en el cuero cabelludo.	6
Figura 2.4 El EEG medido no puede determinar si la actividad es excitatoria o inhibitoria. Fuente (Jackson & Bolger, 2014).	7
Figura 2.5 La pila de capacitadores con del de electrodo, mostrando la propagación de la señal neuronal a través de las capas del cerebro, duramadre, caneo y gel del electrodo hasta llegar al electrodo. Fuente: (Jackson & Bolger, 2014).	8
Figura 2.6 Lóbulos del cerebro.....	9
Figura 2.7 El sistema 10-20 con distancias entre electrodos de 10% y 20% de adelante hacia atrás (del nasion al inion).	10
Figura 2.8 Una señal EEG y las bandas correspondientes	11
Figura 2.9 Artefactos y su interferencia en la señal EEG	11
Figura 2.11 Los picos de voltaje de alta amplitud (parpadeos) que afectan principalmente a los electrodos frontales (F7, Fpz, F8) y el aumento de potencia en frecuencias bajas (bandas delta y theta).	13
Figura 2.12 El efecto en F7 y F8, con cambios rápidos en la amplitud y diferentes direcciones como resultado del dipolo creado por el ojo en los sensores (este artefacto también se denomina inversión de fase, ya que el artefacto puede imitar un cambio de fase). Mayor potencia en frecuencias bajas (bandas delta y theta).	13
Figura 2.13 El artefacto de alta frecuencia que ocurre al apretar la mandíbula. En este ejemplo, el efecto principal es observable en C3. Mayor potencia en frecuencias altas (bandas beta y gamma).	14
Figura 2.14 La señal de alta frecuencia superpuesta a los datos EEG en todos los canales. Aparece un pico claro a 50 Hz. El EEG se registró en España y la frecuencia de	

la línea de energía es de 50 Hz.	16
Figura 2.15 el cambio abrupto de alta amplitud en todos los canales cuando se retira la referencia, que lentamente converge hacia las señales EEG reales cuando se vuelve a colocar. Potencia muy alta en todas las frecuencias y un campo topográfico lógico de que cubre toda la cabeza.	17
Figura 2.16 La distorsión en F3 producida al tocar el sensor. El efecto en el dominio temporal y de frecuencia depende del tipo de "pop" (tocar, espontáneo, etc.). En este caso, se pueden ver las frecuencias del artefacto producido por tocar en F3.....	18
Figura 2.17 En este ejemplo, aparece una distorsión en Cz o Pz al mover los cables. Como se mencionó antes, el efecto en el dominio temporal y de frecuencia puede variar mucho según el movimiento del cable y los cambios en el contacto entre el sensor y el cuero cabelludo.	19
Figura 2.18 El efecto del movimiento de la cabeza superpuesto a los datos EEG en todos los canales. El efecto de los movimientos se superpone a las frecuencias bajas del EEG.	20
Figura 2.19 Transformada de Fourier en Tiempo Corto	22
Figura 2.20 Ejemplos de wavelets	25
Figura 2.21 Transformada Wavelet Inversa	27
Figura 2.22 Red neuronal adversaria generativa	29
Figura 3.1 Modelo general de investigación.....	31
Figura 3.2 Propuesta de investigación	33
Figura 3.3 Generación de EEG sintético	34
Figura 3.4 Simulación de datos EEG	36
Figura 3.5 Selección de dipolos	36
Figura 3.6 Proyección de dipolos	37
Figura 3.7 EEG generado a partir de la proyección de dipolos de la Figura 3.5	38
Figura 3.8 Diagrama general para añadir artefactos de manera sintética a la señal EEG	39
Figura 3.9 Señal EEG	39
Figura 3.10 Señales correspondientes a artefactos	40

Figura 3.11 Comparación de señales a) Señal EEG, b) Señal EEG+EOG y c) Señal EEG+EMG	41
Figura 3.12 sistema internacional 10-20 y sus canales correspondientes en un EEG ..	42
Figura 3.13 Histograma de eventos de artefactos en EEG	43

Índice de tablas

Tabla 2.1 Actividad ocular.....	12
Tabla 2.2 Actividad muscular	14
Tabla 2.3 Actividad muscular	15
Tabla 2.3 Actividad electrodo	16
Tabla 2.3 Actividad electrodo	17
Tabla 2.3 Actividad de movimiento de cable	18
Tabla 2.3 Actividad de movimiento del cuerpo	19

Siglas y abreviaturas

EEG	Electroencefalografía
EOG	Electrooculografía
EMG	Electromiografía
ECG	Electrocardiografía
ICA	Análisis de Componentes Independientes
WT	Transformada Wavelet
CWT	Transformada Wavelet Continua
STFT	Transformada de Fourier de Tiempo Corto
HT	Transformada de Hilbert
NN	Red Neuronal
CNN	Red Neuronal Convolucional
LSTM	Memoria a Largo Corto Plazo
BLSMT	Memoria a Largo Corto Plazo Bidireccional
GAN	Red Generativa Antagónica
VAE	Autoencoder Variacional
YOLO	You Only Look Once – Algoritmo de detección de objetos

Glosario

“A”

Aenean: Sollicitudin sem lorem, nec tristique lacus auctor in. Etiam luctus purus non dui fringilla tempor. Suspendisse euismod urna id nisl cursus, nec tincidunt lacus sagittis. Sed mollis sem mattis ligula rutrum scelerisque. Ut mattis condimentum blandit. Curabitur ipsum mauris, ullamcorper non accumsan id, eleifend id velit. Nunc at semper massa, sit amet pellentesque metus. Pellentesque pulvinar eget mauris sit amet dapibus. Integer vel lorem ut sem pretium semper vel at est. Aenean vitae varius libero. Sed accumsan nisl eu nulla consectetur fringill.

“B”

Blandit: Aenean laoreet ligula massa, ut varius lorem convallis ut. Integer at libero neque. Donec vestibulum neque in efficitur iaculis. Donec eros eros, porta suscipit auctor et, rutrum ut tortor.

“C”

Congue: Quam nibh convallis mauris, et tincidunt massa dolor maximus mauris. Fusce pretium lectus vitae aliquet aliquet. Fusce elit ligula, cursus eu velit eu, maximus tempus lorem.

Resumen

Resumen.

Capítulo 1

Introducción

Capítulo 1 Introducción

La implementación del aprendizaje profundo en el procesamiento de señales biomédicas, específicamente en señales de electroencefalografía (EEG), ha sido un enfoque prometedor para la eliminación de artefactos debido a la naturaleza no invasiva de la adquisición de estas señales. Sin embargo, uno de los desafíos más significativos es la eliminación de artefactos no deseados para mejorar su uso en sus distintas aplicaciones. A lo largo de los años, se han propuesto diversos algoritmos para mitigar estos artefactos, pero ninguno ha resultado ser completamente efectivo. Además, los modelos de aprendizaje profundo enfrentan dificultades para generalizar en la eliminación de diferentes tipos de artefactos debido a la necesidad de grandes cantidades de datos de entrenamiento. Por lo tanto, es crucial desarrollar y proponer nuevas técnicas que puedan eliminar eficazmente los artefactos de las señales EEG, abordando estos desafíos con diversos enfoques innovadores.

1.1 Antecedentes

La señal EEG de acuerdo con Alharbi, (2018) es el registro de la actividad eléctrica cerebral no invasivo el cual resulta en una señal compleja para su estudio. Sin embargo, su adquisición puede estar contaminado por diversos tipos de ruidos y artefactos, lo que puede causar problemas en el análisis preciso de las señales cerebrales. Estos artefactos pueden ser de origen fisiológico o no fisiológico, dado que las señales registradas presentan amplitudes muy pequeñas, del orden de los μV estas pueden ser alteradas fácilmente por artefactos. Existen dos tipos de artefactos que los artefactos fisiológicos incluyen movimientos oculares (como el parpadeo y los movimientos sacádicos), actividades musculares (contracciones de los músculos faciales y cervicales) y la actividad cardíaca (pulsaciones del corazón que interfieren en el registro). Por otro lado, los artefactos no fisiológicos abarcan interferencias electromagnéticas de dispositivos cercanos, fluctuaciones en la red eléctrica, y ruido ambiental de equipos electrónicos. La presencia de estos ruidos en la adquisición de las señales EEG convierte la tarea de detección y eliminación se convierte en una tarea compleja. La señal EEG es una herramienta valiosa para estudiar diversas aplicaciones, como menciona (Giulia Cisotto, 2022) . Sin embargo, la presencia de artefactos puede afectar tanto el diagnóstico como el análisis en investigaciones clínicas, especialmente en trastornos como el sueño, la enfermedad de Alzheimer y la esquizofrenia. Por ello, es fundamental tratar estos artefactos antes de analizar las señales EEG, tanto en entornos de investigación como en la práctica clínica. La contaminación por artefactos distorsiona la verdadera señal EEG, lo cual repercute negativamente en los resultados de las aplicaciones deseadas. Por otro lado, se ha demostrado que los artefactos disminuyen la precisión en la clasificación de datos y afectan la efectividad de los dispositivos de interfaz cerebro-computadora, reduciendo su controlabilidad. Aunque las señales pueden verse afectadas por ruido interno o externo, que a menudo tiene características desconocidas, pueden identificarse si los subespacios de señal y ruido se separan con precisión (Mateo et al., 2016). Según Kawala-Sterniuk et al., (2021) , el rápido desarrollo tecnológico en los últimos 30 años ha impulsado un creciente interés científico en el uso de datos biomédicos, ya que su aplicación abarca áreas como la comunicación, el control de movimiento, la interacción con el entorno y la neurorrehabilitación, entre otros. El

análisis de estos datos biomédicos requiere generalmente un preprocesamiento, especialmente para extraer los patrones deseados (Yu et al., 2022). Sin embargo, a pesar de numerosos avances, aún no se ha desarrollado un método ideal y versátil para eliminar los artefactos presentes en las señales de electroencefalografía (EEG). La adquisición de señales EEG se realiza mediante electrodos colocados en el cuero cabelludo y refleja las actividades electrofisiológicas de la corteza cerebral (Anas Fouad Ahmed, 2022). Para señales EEG y artefactos con diferentes perfiles espectrales, un método común para eliminar artefactos consiste en transformar la señal del dominio temporal al dominio espectral, empleando la transformada de Fourier o la transformada wavelet, y filtrar los componentes espectrales asociados con los artefactos. La señal libre de ruido puede luego reconstruirse mediante la transformada inversa de Fourier o la transformada wavelet inversa (Walters-Williams & Li, 2011).

En la actualidad, con el creciente desarrollo del aprendizaje profundo, se han aplicado diversos modelos para la eliminación de artefactos en señales EEG, tales como autoencoders, redes neuronales convolucionales residuales, redes neuronales recurrentes y redes generativas adversariales (Mashhadi et al., 2020; H. Zhang, Zhao, et al., 2021a). En comparación con los métodos tradicionales, los modelos de aprendizaje profundo presentan dos ventajas clave:

- a) Universalidad, ya que una arquitectura uniforme puede adaptarse a múltiples tareas de eliminación de artefactos sin la necesidad de diseñar supuestos específicos para cada tipo de artefacto.
- b) Mayor capacidad, debido a que el aprendizaje profundo permite mejorar significativamente el rendimiento.

Sin embargo, la baja interpretabilidad y los problemas de seguridad asociados con el aprendizaje profundo limitan en gran medida su aplicación en la eliminación de ruido en EEG. Por ello, existe un interés creciente en desarrollar modelos de aprendizaje profundo interpretables y confiables para la eliminación efectiva de artefactos no deseados en señales EEG.

1.2 Estado del arte

Los estudios por mejorar la calidad de las señales de electroencefalografía (EEG) respecto a los artefactos han sido de mayor interés debido a que se debe tener una interpretación concisa en los campos de aplicación. Los principales tipos de ruido presentados en una señal EEG son artefactos fisiológicos y técnicos. Es por ello que diversos autores mencionan tales como Hu & Zhang, (2019) que han desarrollado e implementado diversos tipos de técnicas que van desde la aplicación de filtros hasta la aplicación de aprendizaje profundos para obtener una representación de la señal EEG con la menor pérdida de características. Existen diversas formas de eliminar el ruido dentro de las señales de electroencefalografía, sin embargo, aún no hay un método definitivo para mitigar el ruido. Citando trabajos que ofrecen una revisión sistémica de la literatura como Hu & Zhang, (2019) menciona que técnicas como el filtrado de banda mejora la calidad de la señal EEG reduciendo el ruido de línea en un 50-60%. También

el método de Análisis de Componentes Independientes ha demostrado eliminar artefactos oculares y cardiacos en un 70-80%. Técnicas como re-referenciación que consiste en la transformación lineal de los datos EEG para minimizar el ruido en los electrodos de referencia a llevado a una eliminación de ruido de un 30%. Por otro lado (Z. Zhang et al., 2022a) menciona que el aprendizaje profundo para la eliminación de ruido en EEG, como redes neuronales convolucionales han demostrado reducir el error cuadrático medio en un 6%. Por otro lado, la Transformada Wavelet (TW) empleada por estudios hecho por Pise & Rege, (2021), Elshekhdreis et al., (2023), han demostrado mejorar los resultados de eliminación de ruido de la señal EEG contaminada esto a través de las distintas configuraciones que tiene la TW.

Los autores Yao et al., (2020) propusieron un filtro de características para señales EEG utilizando técnicas de adaptación de dominio y redes neuronales generativas adversariales esto para retener características deseadas. Posteriormente Gajbhiye et al., (2021) llevo a cabo la eliminación de artefactos de movimiento de señales EEG utilizando un filtro Filtro Savitzky–Golay Optimizado en el Dominio Wavelet. Su estudio se centró en la multiresolución basado en Transformada Wavelet Discreta y en la optimización de parámetros del filtro basados en el error absoluto medio en densidad espectral de potencia. Su implementación redujo la complejidad computacional. Otros estudios como el que llevo Al Imran & Rabbani, (2022) hicieron una comparación de distintos algoritmos para eliminación de ruido en señales EEG tales como redes neuronales totalmente conectadas, algoritmo adaptativo de mínimos cuadrados recursivos y algoritmos adaptativo de mínimos cuadrados. Los resultados mostraron que las redes neuronales totalmente conectadas obtuvieron el mejor rendimiento de eliminación de ruido. Consiguientemente los autores Madhale Jadav et al., (2020) llevaron a cabo un filtro adaptativo mediante el análisis de entropía local de Rényi y algoritmo basado en la intersección relativa del intervalo de confianza.

Autores como Chen et al., (2022) implemento un modelo de convolución residual adaptativa de dominio, el modelo llevo a cabo el reconocimiento de emociones usando EEG, su implementación de adaptación de dominio se usó para reducir las diferencias de características entre sujetos. El modelo implementado considero varios sujetos para el reconocimiento de emociones alcanzando un 95.15% de precisión. Por otro lado Tang & Zhang, (2020) propuso la aplicación de redes generativas adversariales (GAN) esto con el fin de mejorar los filtros de características de EEG, ellos emplearon el uso de técnicas de adaptación de dominio, este empleo una GAN con dos generadores, dos discriminadores y un clasificador. Además An et al., (2022) emplearon un método de eliminación de ruido automático para señales EEG utilizando una GAN como función de perdida para retener información y energía original de la señal EEG. Los resultados mostraron tener una eliminación de ruido obteniendo como correlación promedio de 0.7771 y un RMSE de 0.0757. Los autores Alyasseri et al., (2020) emplearon la combinación de Transformada Wavelet junto con algoritmos metaheurísticos para la eliminación de ruido en señales EEG. Este evaluó cinco algoritmos siendo Polinización Cruzada Global el mejor para eliminar ruido. Los criterios evaluados fueron relación señal-ruido (SNR), raíz del error cuadrático medio (RMSE) y error cuadrático medio (MSE), mostrando una eliminación eficiente del ruido en las señales EEG.

Así mismo, Grobbelaar et al., (2022) se emplearon diversas técnicas basadas en filtrado para eliminar artefactos, incluyendo la Transformada Wavelet Discreta (DWT), la

Transformada Wavelet Estacionaria (SWT), el Análisis de Componentes Independientes (ICA), la Descomposición Empírica de Modos (EMD) y el Análisis de Correlación Canónica (CCA). Los autores propusieron una revisión exhaustiva de las técnicas de eliminación de ruido en señales EEG mediante el uso de distintas transformadas wavelet y combinaciones híbridas. Se mejoró la implementación combinando técnicas como DWT con ICA, EEMD con CCA y filtros de Kalman, con el objetivo de optimizar la eliminación de artefactos. Los datos utilizados consistieron en señales EEG contaminadas con artefactos oculares, musculares y cardiacos. Los resultados demostraron que las técnicas híbridas, como Wavelet-ICA y EEMD-CCA-DWT, lograron mejoras significativas en la eliminación de artefactos, manteniendo la integridad de la señal EEG original. Por otro lado, en el estudio llevado a cabo por Brophy et al., (2022), se emplearon varias técnicas de inteligencia artificial, incluyendo GAN, CNN y Autoencoders Variacionales (VAE). Los autores propusieron la eliminación de artefactos en señales EEG para aplicaciones de interfaces cerebro-computadora, utilizando GAN para mapear señales ruidosas a señales limpias. Se mejoró la implementación mediante la utilización de un GAN con redes LSTM para el generador y una red convolucional de 4 capas para el discriminador, capaz de manejar múltiples tipos de artefactos. Los resultados mostraron que el GAN superó a otros modelos de aprendizaje profundo en la eliminación de artefactos, con mejoras en las métricas en relación señal-ruido, error cuadrático medio relativo y correlación, demostrando una capacidad de eliminación de ruido de alta calidad. El estudio de Saini et al., (2020), se emplearon técnicas como la Transformada Wavelet Discreta y Medidas de Distorsión Basadas en la Energía y Entropía Wavelet. Los autores propusieron dos nuevas medidas de distorsión ponderada, Relación Señal-Ruido Ponderada (WSNR) y Coeficiente de Correlación Ponderado (WCC), para cuantificar la distorsión en bandas específicas de señales EEG con eliminación de ruido. Se mejoró la implementación utilizando la energía relativa de sub-banda wavelet y la entropía wavelet relativa para asignar pesos a las medidas de distorsión. Los resultados indicaron que las medidas WSNR y WCC proporcionan una mejor representación de la calidad de reconstrucción en las bandas EEG locales.

Además, el estudio hecho por Mashhadi et al., (2020), se utilizaron técnicas de inteligencia artificial como CNN y U-Net. Los autores propusieron tres esquemas de aprendizaje profundo basados en U-Net para eliminar artefactos oculares de señales EEG. Mejoraron la implementación al convertir las señales EEG a imágenes en escala de grises y emplear U-Net para purificar las señales contaminadas. Los datos utilizados fueron un conjunto de datos semi-simulado de EEG con artefactos oculares añadidos manualmente. Los resultados mostraron que el primer esquema de U-Net, entrenado por separado para cada canal, presentó el menor error cuadrático medio de 0.00057, superando a los otros métodos propuestos. En el estudio de Kaur et al., (2021), se utilizaron técnicas como la Descomposición de Modos Variacionales (VMD), la Transformada Wavelet Discreta (DWT) y la Transformada Wavelet de Paquetes (WPT). Los autores propusieron un enfoque híbrido que combina VMD con DWT y WPT para la eliminación de artefactos en señales EEG de pacientes con depresión. La implementación mejorada utiliza VMD para descomponer la señal en componentes, seguido de DWT y WPT para eliminar artefactos basándose en el análisis de fluctuación sin tendencia (DFA). Los resultados mostraron que el método propuesto (VMD-DFA-WPT) tuvo un mejor rendimiento en términos de relación señal-ruido, pico de relación

señal-ruido y error cuadrático medio en comparación con otros métodos existentes, logrando una eliminación efectiva de artefactos y una mejor preservación de la señal neural.

En el estudio de Z. Zhang et al., (2022b), se utilizaron técnicas de inteligencia artificial como una Red Neuronal Multimodular (MMNN), Redes Neuronales Convolucionales y capas completamente conectadas. Los autores propusieron una red neuronal multimodular para eliminar artefactos oculares y artefactos miogénicos de señales EEG ruidosas de un solo canal. Los resultados mostraron que el modelo MMNN mejoró el error cuadrático medio relativo en el tiempo y en el espacio al menos en un 6% y el coeficiente de correlación en al menos un 3% en comparación con otros enfoques, demostrando mejoras significativas en la eliminación de artefactos. De manera similar, Qiu et al., (2018), se emplearon técnicas de inteligencia artificial como el Autoencoder Disperso para eliminación de ruido y la Regresión Logística. Los autores propusieron un marco de detección automática de convulsiones basado en para clasificar señales EEG. Mejoraron la implementación mediante un Autoencoder con penalización de dispersidad y operación de corrupción en los datos de entrada para aumentar la robustez y evitar el sobreajuste. Los resultados mostraron una sensibilidad, especificidad y precisión del 100% en el problema de dos clases, y una precisión promedio del 92% en el problema de cinco clases. Además Phadikar et al., (2020), se utilizaron técnicas como el Análisis de Componentes Independientes (ICA), Máquinas de Vectores de Soporte (SVM) y Autoencoder de Eliminación de Ruido (DA). Los autores propusieron una combinación de ICA, SVM y DA para la identificación y eliminación automática de artefactos de parpadeo ocular en señales EEG. Mejoraron la implementación utilizando ICA para descomponer las señales EEG en componentes independientes, SVM para identificar los componentes corruptos y DA para corregir los segmentos artefactos. Los resultados mostraron que la metodología propuesta mejora la correlación promedio. Además, la técnica es completamente automática y no requiere intervención del usuario. En otro trabajo, H. Zhang et al., (2021), se emplearon técnicas de inteligencia artificial como Redes Neuronales Convolucionales (CNN) y Autoencoder. Los autores propusieron una nueva arquitectura de CNN con aumento gradual de dimensiones de características y submuestreo para eliminar artefactos musculares en señales EEG. Los resultados mostraron que el modelo CNN propuesto supera a cuatro redes de referencia en la eliminación de artefactos musculares, mostrando un menor error cuadrático medio relativo y un mayor coeficiente de correlación.

En el estudio de Taran & Bajaj, (2019), se emplearon técnicas de inteligencia artificial como la Descomposición Empírica de Modo (EMD), la Descomposición por Modos de Variación (VMD) y Máquinas de Vectores de Soporte de Mínimos Cuadrados Multiclase (MC-LS-SVM). Los autores propusieron un método de filtrado en dos etapas para el reconocimiento de emociones basado en señales EEG, utilizando EMD para eliminar componentes ruidosos y VMD para descomponer las señales en modos. Mejoraron la implementación aplicando un criterio de correlación para eliminar Funciones de Modo Intrínseco (IMF) ruidosos de la señal EEG bruta, seguido de VMD para obtener señales EEG con la frecuencia deseada. Los resultados mostraron que la función kernel Morlet wavelet en MC-LS-SVM proporcionó las mejores precisiones individuales para la detección de emociones: 92.79% (feliz), 87.62% (miedo), 88.98% (triste) y 93.13% (relajado), con una precisión general del 90.63%, un F1-score de 0.9064 y una kappa de

0.8751. Consiguientemente Tang & Zhang, (2020), se utilizaron técnicas de inteligencia artificial como Redes Neuronales Convolucionales (CNN) y Red de Adaptación de Dominio Adversarial Condicional (CDAN). Los autores propusieron un marco CDAN para la decodificación de señales EEG de imaginación motora (MI) utilizando una red de adaptación de dominio condicional. Mejoraron la implementación mediante la introducción de un Red Neuronal Convolucional densa para extraer características discriminativas de señales EEG crudas y un discriminador condicional de dominio para minimizar la discrepancia de distribución de datos entre sujetos. Los resultados mostraron que el modelo CDAN alcanzó una precisión de clasificación del 95.3%, superando a otros métodos. En el estudio Lan et al., (2019), se emplearon técnicas de inteligencia artificial como Transferencia de Aprendizaje, Adaptación de Dominio, Máxima Independencia de Adaptación de Dominio (MIDA), Análisis de Componentes de Transferencia (TCA), Alineación Subespacial (SA), Kernel de Flujo Geodésico (GFK) y Análisis de Componentes Principales Kernel (KPCA). Los autores propusieron un estudio comparativo de técnicas de adaptación de dominio para el reconocimiento de emociones basado en EEG. Los resultados mostraron que las técnicas de adaptación de dominio, especialmente MIDA y TCA, mejoraron significativamente la precisión de clasificación en comparación con los métodos base, logrando una ganancia de precisión del 7.25% al 13.40% en experimentos de adaptación entre conjuntos de datos.

POR REVISAR

Así mismo, Wilroth et al., (2023), se emplearon técnicas de inteligencia artificial como Adaptación de Dominio, Máquinas de Soporte Vectorial (SVM) y Análisis de Componentes Principales (PCA). Los autores propusieron un marco de adaptación de dominio utilizando transporte paralelo para mejorar la clasificación de atención auditiva basada en EEG. Mejoraron la implementación mediante el uso de matrices de covarianza y geometría de Riemann para trasladar datos de baja calidad al dominio de datos de alta calidad de otros sujetos. Los resultados mostraron que la precisión de la clasificación aumentó del 45.84% al 67.92% para sujetos con datos de baja calidad, y la mejor precisión alcanzada por un sujeto fue del 83.33%, comparado con el 43.33% inicial. Por otro lado, En el estudio Wu et al., (2022), se emplearon técnicas de inteligencia artificial como Adaptación de Dominio y Redes Neuronales Convolucionales (CNN). Los autores propusieron un método de adaptación de dominio para detectar depresión utilizando señales EEG de pocos electrodos obtenidas de dispositivos portátiles. Mejoraron la implementación mediante la conversión de señales EEG en imágenes utilizando dos métodos: representación separada de tres canales y síntesis RGB. Posteriormente, realizaron el entrenamiento y la predicción con modelos de adaptación de dominio. Los resultados mostraron que el modelo de adaptación de dominio alcanzó una precisión promedio del $77.0 \pm 9.7\%$, demostrando que puede debilitar eficazmente las diferencias inherentes en las señales EEG y mejorar la precisión del diagnóstico de la depresión. Finalmente, Shen et al., (2021), se emplearon técnicas de inteligencia artificial como Alineación de Señales de Múltiples Fuentes (MSSA), Redes Tensoriales (TN) y Máquinas de Soporte Vectorial (SVM). Los autores propusieron un marco de alineación de señales de múltiples fuentes (MSSA) y clasificación de características multidimensionales para la detección de somnolencia independiente del sujeto. Mejoraron la implementación utilizando MSSA para alinear directamente las señales EEG entre cada sujeto fuente y el sujeto objetivo mediante la minimización de matrices de covarianza. La extracción de

características multidimensionales se realizó con redes tensoriales para una clasificación eficiente. Los resultados mostraron que mejoró la precisión de clasificación en un 3.71% en comparación con los métodos de última generación, logrando una precisión de clasificación promedio del 71.97%. Finalmente Hay métodos que recientemente están proponiendo adaptación de dominio en la señal EEG que va desde tener una clasificación con mayor rendimiento hasta la implementación para que el modelo de aprendizaje sea capaz de eliminar artefactos no deseados en la señal EEG. Los autores como Chen et al., (2021) propusieron realizar la adaptación de dominio con atención espacial el objetivo fue mejorar la información espacial de las señales EEG, esto tuvo una clasificación del 67% para identificación de carga de memoria. Otro estudio utilizó adaptación de dominio para llevar a cabo un clasificador de representación dispersa. Este clasificador clasificaba emociones a través de las señales EEG. El modelo alcanzó un 80.27% en la clasificación de emociones.

Los autores (Cao et al., 2024) presentan una investigación para la detección de epilepsia infantil multimodal basado en electroencefalogramas (EEG) y video, la investigación usó YOLOv3 para detectar y filtrar objetos en el video para de esta forma eliminar interferencias en el video que no aportan para la detección de convulsiones. El método basado en características fusionadas de EEG+Video alcanzó una precisión total del 98.33%. Además, utilizando solo características de video, el método puede lograr una precisión total del 93.30%. Por otro lado, los autores (Aphimeteetamrong et al., 2024) emplearon el modelo YOLOv8 para la detección de eventos de apnea/hipopnea en registros nocturnos sin necesidad de las señales EEG en contextos de monitoreo de sueño en el hogar, se propone un modelo automatizado basado en aprendizaje profundo que utiliza tres señales fisiológicas distintas al EEG. Se utilizó el kappa de Cohen para medir la concordancia entre las predicciones del modelo y los niveles de severidad de referencia, obteniendo valores entre 0.61 y 0.81. El trabajo propuesto por (Liu & Wu, 2024) Los autores (Liu & Wu, 2024) propone un método para la detección de ondas epilépticas utilizando YOLOv7-tiny, específicamente adaptado para reconocer picos en registros EEG. Se diseñó una estructura de cabeza desacoplada en YOLOv7-tiny para separar las tareas de clasificación (detección de picos epilépticos) y de regresión (localización temporal precisa de los picos). Los resultados mostrados en los datos del Hospital Infantil de Boston la sensibilidad aumentó un 5.5%, alcanzando el 99.1% y por otro lado con el conjunto de datos de kaggle la sensibilidad mejoró un 2%, alcanzando el 97.6%. Los autores (Lin et al., 2024) proponen un método multimodal para la detección de descargas epileptiformes interictales (IED) donde usan datos de video y EEG para mejorar la precisión y reducir los falsos positivos en el análisis clínico. Para mejorar la detección de movimientos asociados a IED, los datos de video se procesan mediante un método de detección de pacientes donde incluye la diferencia de fotogramas que permite identificar movimientos significativos entre fotogramas consecutivos y otro la captura de los movimientos de los pacientes en el video, identificando patrones relacionados con episodios epilépticos. La incorporación de datos de video en vEpiNet incrementó la precisión de detección de IED del 70% (IC 95%, 69.8%-70.2%) al 76.6% (IC 95%, 74.9%-78.2%) con una sensibilidad del 80%. El modelo multimodal propuesto demuestra una notable robustez en presencia de artefactos de movimiento ocular, masticación, mioeléctricos y ondas fisiológicas del sueño. Los autores (Anantha Rufus, 2024) implementaron eliminación de artefactos oculares en EEG para mejorar el diagnóstico

de esquizofrenia utilizando transformada wavelet mediante aprendizaje profundo LSTM. La investigación aplico Descomposición de Modos Empricos Ensamble, posteriormente el filtrado de artefactos Fejer-Korovkin para eliminar los artefactos. Las señales EEG libres de interferencias se reconstruyen y se emplean para entrenar una red de memoria a largo plazo donde se identifica los patrones asociados con la esquizofrenia. Propusieron (Chambon et al., 2019) un enfoque de aprendizaje profundo para detectar microeventos de sueño en señales EEG. Su propuesta predice de manera conjunta la ubicación, duración y tipo de eventos en series de tiempo EEG. se inspira en detectores de objetos desarrollados para visión por computadora, como YOLO y SSD. El enfoque propuesto se probó en 4 conjuntos de datos y en 3 tipos de eventos (espigas, complejos K, despertares). El estudio propuesto por (Cui et al., 2022) explora la combinación de visión humana y cisión por computadora mediante la interacción dinámica de probabilidad para mejorar la detección de objetivos en la tarea presentación visual en serie rápida basadas en EEG abordando los desafíos de la no estacionariedad de las señales EEG y los lapsos de atención. El método propuesto alcanzó una precisión equilibrada promedio de 0.845.

1.3 Planteamiento del problema

Dado que la electroencefalografía (EEG) es una técnica no invasiva ampliamente utilizada para registrar la actividad eléctrica del cerebro. Debido a su naturaleza no invasiva presenta una debilidad y es una de las principales limitaciones de las señales EEG que son los artefactos, lo cual puede degradar significativamente la calidad de las señales. Las señales EEG están inherentemente contaminadas por diversos tipos de ruido, incluyendo artefactos fisiológicos y artefactos. Este ruido dificulta la extracción de características relevantes y precisas de las señales EEG, lo que afecta negativamente el rendimiento de las aplicaciones. Los métodos tradicionales de filtrado y preprocesamiento de señales EEG pueden no ser lo suficientemente efectivos para eliminar el ruido sin perder información crítica. Encontrar un balance entre la eliminación de ruido y la preservación de señales relevantes es un desafío constante. La variabilidad en las señales EEG entre diferentes sujetos complica la creación de modelos universales. Las técnicas actuales a menudo fallan en generalizar adecuadamente debido a esta variabilidad, lo que resulta en una disminución de la precisión en aplicaciones prácticas. Las técnicas avanzadas como el aprendizaje profundo y la adaptación de dominio tienen la mejora de la eliminación de ruido y la robustez de las aplicaciones de EEG. El ruido presente en estas señales puede llevar a errores en la interpretación de las intenciones del usuario, lo que limita la usabilidad y confiabilidad en la implementación de nuevas tecnologías. De acuerdo con Yadav et al., (2020) y Kawala-Sterniuk et al., (2021) el ruido presente en señales EEG, considera la siguiente ecuación:

$$x(t) = s(t) + n(t) \quad (1.1)$$

Donde $x(t)$ es la señal EEG medida, es la señal determinista real EEG $s(t)$ y $n(t)$ es el ruido no deseado a la señal. Entonces el objetivo es eliminar o mitigar la presencia de $n(t)$ de la señal determinista.

De acuerdo con la Figura 1.1 el estudio abarcara la etapa de preprocesamiento para la identificación y eliminación de artefactos en la señal EEG.

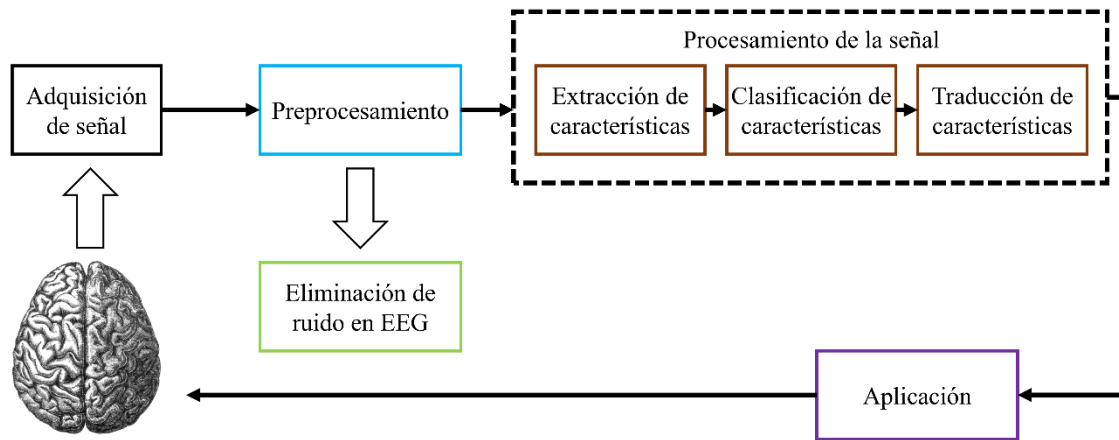


Figura 1.1 Etapas de procesamiento de las EEG

1.4 Justificación del problema de investigación

La investigación en la mejora de la eliminación de ruido en señales de electroencefalografía (EEG) utilizando técnicas de aprendizaje profundo y adaptación de dominio presenta las principales razones que justifican esta investigación:

- Las señales EEG son intrínsecamente ruidosas debido a la naturaleza no invasiva del método y a la sensibilidad del equipo a interferencias externas y fisiológicas.
- Mejorar la precisión de estas señales es crucial para aplicaciones críticas, como las interfaces cerebro-computadora, donde se requiere una alta exactitud para interpretar correctamente las intenciones del usuario.
- Un enfoque mejorado para la eliminación de ruido y reconocimiento de patrones puede aumentar la efectividad y usabilidad de estas interfaces, ampliando su aplicabilidad.
- Actualmente, los métodos tradicionales de preprocesamiento de señales EEG presentan limitaciones en la eliminación de ruido y preservación de información relevante.
- Con el creciente interés en tecnologías de interfaz cerebro-computadora y el aumento de aplicaciones potenciales, es crucial desarrollar métodos que mejoren la calidad y precisión de las señales EEG para un mejor rendimiento.

1.5 Preguntas de investigación

A continuación, se presentan una serie de preguntas de investigación propuestas para la presente propuesta de investigación.

1. ¿Cuáles son los desafíos específicos de la eliminación de artefactos en señales electroencefalografía (EEG)?
2. ¿Cuál es el impacto de diferentes tipos de artefactos (fisiológico y no fisiológico) en la calidad de las señales EEG y cómo pueden ser mitigados?
3. ¿Qué métricas de evaluación son más adecuadas para medir la eficacia de los métodos de eliminación de ruido en señales EEG?
4. ¿Cómo puede la adaptación de dominio mejorar la eliminación de ruido en las señales EEG?

5. ¿Qué beneficios adicionales pueden ofrecer las técnicas de adaptación de dominio en comparación con los métodos tradicionales de preprocesamiento de señales EEG?
6. ¿Cómo puede la combinación de técnicas de eliminación de artefactos y reconocimiento de patrones mejorar la usabilidad y precisión en sus diferentes aplicaciones?

1.6 Objetivo general

Desarrollar y evaluar un enfoque basado en técnicas de aprendizaje profundo para identificar y eliminar artefactos en señales de electroencefalografía (EEG) para su uso en aplicaciones específicas.

1.7 Objetivos específicos

A continuación, se plantean los objetivos específicos para esta investigación:

- Implementar y comparar métodos recientes de preprocesamiento de señales EEG para identificar aquellos que logran una reducción más efectiva de artefactos, optimizando la identificación y preservación de características clave de la señal EEG.
- Analizar el efecto de los artefactos en señales EEG en sus diferentes tipos además como afectan en los campos de aplicación.
- Implementar y comparar diversos métodos de preprocesamiento de señales EEG para identificar aquellos que ofrecen una mayor reducción de artefactos, optimizando la identificación y preservación de características relevantes de la señal.
- Realizar experimentos y análisis comparativos para determinar la eficacia del enfoque propuesto en comparación con métodos tradicionales de preprocesamiento y reconocimiento de señales EEG.

1.8 Hipótesis

H0: La implementación de un enfoque aplicando técnicas de aprendizaje profundo para la identificación y eliminación de artefactos en señales EEG mejorará la estimación de la señal EEG, incrementando la precisión y robustez en aplicaciones específicas.

1.9 Alcance

El alcance de esta investigación abarca el desarrollo, implementación y evaluación de un enfoque basado en técnicas de aprendizaje profundo para optimizar la identificación y eliminación de artefactos en señales de electroencefalografía (EEG). La investigación incluirá:

1. Una revisión sistemática de la literatura, así como la selección o adaptación de técnicas de aprendizaje profundo para la identificación y eliminación de ruido en señales EEG.
2. El diseño y desarrollo de un modelo de aprendizaje profundo que aumente la robustez del sistema frente a la variabilidad y condiciones cambiantes en las señales EEG.
3. La implementación y comparación de diversos métodos de preprocesamiento de señales EEG en términos de su eficacia en la reducción de ruido y preservación

de características relevantes.

4. La experimentación para evaluar la efectividad del enfoque propuesto en la identificación y eliminación de artefactos en señales EEG.
5. La evaluación del rendimiento del enfoque propuesto en comparación con los métodos reportados en el estado del arte.

1.10 Contribuciones

El presente proyecto de investigación plantea las siguientes contribuciones:

- Proponer y validar un enfoque que combine técnicas de aprendizaje profundo y adaptación de dominio para la identificación y eliminación de ruido en señales EEG, mejorando así la calidad de las señales para sus diversas aplicaciones.
- Desarrollar un modelo de adaptación de dominio que permita una mejor generalización en la eliminación de ruido en EEG, contribuyendo al campo de la adaptación de dominio en aplicaciones biomédicas.

1.11 Comparación de trabajos del estado del arte respecto a la propuesta de investigación

Propuesta	Identificación de artefactos en tiempo real	Clasificación de artefactos	Propuesta	Aplicación	Artefactos	Dominio de procesamiento	Conjunto de datos
Garcés Correa et al., (2007)	No	No	Filtros adaptativos	No	EOG ECG	Dominio del tiempo	Recolección de EEG reales
Walters-Williams & Li, (2011)	No	No	ICA y TW	No	EOG	Transformada Wavelet	Recolección de EEG 32 canales
Kumar, (2019)	No	No	TW	No	EOG	Transformada Wavelet	Physionet
Mashhadi et al., (2020)	No	Sí	U-Net	No	EOG	Dominio del tiempo	EEGdenoiseNet
Zhang, Zhao, et al., (2021)	No	No	FCNN CNN LSTM ResCNN	No	EOG EMG	Dominio del tiempo	EEGdenoiseNet
Lopes et al., (2021)	No	No	CNN	Sí	EOG EMG	Dominio del tiempo	EEGdenoiseNet EPILEPSIAE
Yu et al., (2022)	No	No	Codificador Descomponedor Decodificador	No	EOG EMG	Dominio del tiempo	EEGdenoiseNet
Peh et al., (2022)	No	Sí	Transformer	No	EOG EMG - Masticar - Temblor - Electrodo	Dominio del tiempo	TUH Artifact
Anas Fouad Ahmed,	No	Sí	Red neuronal multimodulo	No	EOG EMG	Dominio del tiempo	EEGdenoiseNet

(2022)							
Brophy et al., (2022)	No	Sí	GAN	No	EOG EMG	Dominio del tiempo	EEGdenoiseNet
Gabardi et al., (2023)	No	Sí	CNN	No	EOG EMG	Transformada de Fourier	EEGdenoiseNet
Anantha Rufus, (2024)	No	Sí	LSTM	Sí	EOG	Transformada Wavelet	EEG 32 canales pacientes con esquizofrenia
Propuesta de investigación	Arquitectura YOLO-Like para detección en tiempo real	Arquitectura YOLO-Like para detección en tiempo real	RNP CNN LSTM BLSTM GANS UNet Transfomer Autoencoder Stable diffusion	Niveles de profundidad de anestesia	Fisiológicos No fisiológicos	Análisis en el dominio del tiempo Transformada Wavelet Transformada de Fourier Transformada Hilbert	EEGdenoiseNet TUH EEG Artifact Corpus

Capítulo 2

Introducción

Capítulo 2 Naturaleza de señal electroencefalografía (EEG)

En este capítulo se presentará el marco teórico relacionado con la generación fisiológica de la señal de electroencefalografía (EEG), la adquisición de estas señales, las características de los artefactos, las aplicaciones de las señales EEG, y el impacto que los artefactos tienen tanto en la interpretación clínica de las señales como en el campo de las interfaces cerebro-computadora.

2.1 Fuentes de las señales biomédicas

De acuerdo con (Hemanth, 2020), el cuerpo humano emite señales a la que se denominan señales biomédicas, cuyas señales transmiten información, que se utilizan principalmente para extraer información sobre un sistema biológico en investigación. Las señales biomédicas de acuerdo con la Figura 2.1 se originan a partir de una gran variedad de fuentes.




Figura 2.1 Fuentes de señales biomédicas. Fuente (Hemanth, 2020).

Las fuentes de generación de señales biomédicas pueden ser extraídas bajo las siguientes fuentes que se enlistan a continuación:

- Señales bioeléctricas. Estas son exclusivas de los sistemas biomédicos. Son generadas por células nerviosas y células musculares. Su fuente básica es el potencial de membrana celular, que bajo ciertas condiciones puede ser excitado para generar un potencial de acción. El campo eléctrico generado por la acción de muchas células constituye la señal bioeléctrica. Los ejemplos más comunes de señales bioeléctricas son las señales ECG (electrocardiográficas) y EEG

(electroencefalográficas).

- Señales bioacústicas. La medición de señales acústicas generadas por muchos fenómenos biomédicos proporciona información sobre los fenómenos subyacentes. Los ejemplos de este tipo de señales son el flujo de sangre en el corazón, a través de las válvulas del corazón, y el flujo de aire a través de las vías respiratorias superiores e inferiores y en los pulmones, que generan señales acústicas típicas.
- Señales biomecánicas. Estas señales se originan a partir de alguna función mecánica del sistema biológico. Incluyen todo tipo de señales de movimiento y desplazamiento, señales de presión y flujo, entre otras. El movimiento de la pared torácica en consonancia con la actividad respiratoria es un ejemplo de este tipo de señal.
- Señales bioquímicas. Este tipo de señales se obtienen como resultado de mediciones químicas a partir del tejido vivo o de muestras analizadas en el laboratorio. Ejemplos incluyen la medición de la presión parcial de dióxido de carbono, presión parcial de oxígeno y la concentración de diversos iones en la sangre.
- Señales biomagnéticas. Este tipo de señales se generan de los campos magnéticos extremadamente débiles que son producidos por varios órganos como el cerebro, el corazón y los pulmones. Un ejemplo típico es la señal del magnetoencefalograma proveniente del cerebro.
- Señales bio-ópticas: Estas señales se generan como resultado de funciones ópticas de los sistemas biológicos, ya sea de forma natural o inducidas por el proceso de medición. Por ejemplo, la oxigenación de la sangre puede estimarse midiendo la luz transmitida desde un tejido a diferentes longitudes de onda.
- Señales de bioimpedancia: La impedancia de los tejidos es una fuente de información importante sobre su composición, la distribución sanguínea y el volumen de sangre, entre otros aspectos. La medición de la resistencia galvánica de la piel es un ejemplo típico de este tipo de señal.

2.2 Bases neurofisiológicas de la generación de señales EEG y la medición del EEG

Las señales de electroencefalografía (EEG) de acuerdo con (Niedermeyer, 2017; Sanei & Chambers, 2007) surgen a partir de la actividad sináptica sincronizada en poblaciones de neuronas corticales el cual son células piramidales organizadas a lo largo de columnas corticales. El proceso ocurre a través de la excitación de las neuronas postsinápticas que crea un voltaje extracelular cerca de las dendritas neuronales que es más negativo que en otras partes de la neurona. Esta situación se conoce como dipolo el cual es una región de carga positiva separada de una región de carga negativa que se denomina sumidero. Los electrodos detectan la suma de cargas positivas y negativas en su entorno. En el caso de que un electrodo este a la misma distancia de la fuente y el sumidero de un dipolo, el electrodo medirá un valor neto neutro. Por lo tanto, un electrodo puede detectar dipolos cuando está más cerca de uno de los extremos positivo o negativo del dipolo. Esto significa que dos principales de dipolos medibles en el EEG: los dipolos tangenciales Figura 2.2 (a) el cual están orientados perpendicularmente a la superficie, y los dipolos radiales Figura 2.2 (b) y (c) que se encuentran ubicados paralelamente a la

superficie del cuero cabelludo. Los dipolos tienen un lado positivo y uno negativo, por lo que se producirán una deflexión positiva y otra negativa en diferentes regiones del cuero cabelludo como se muestra en la Figura 2.2 (c).

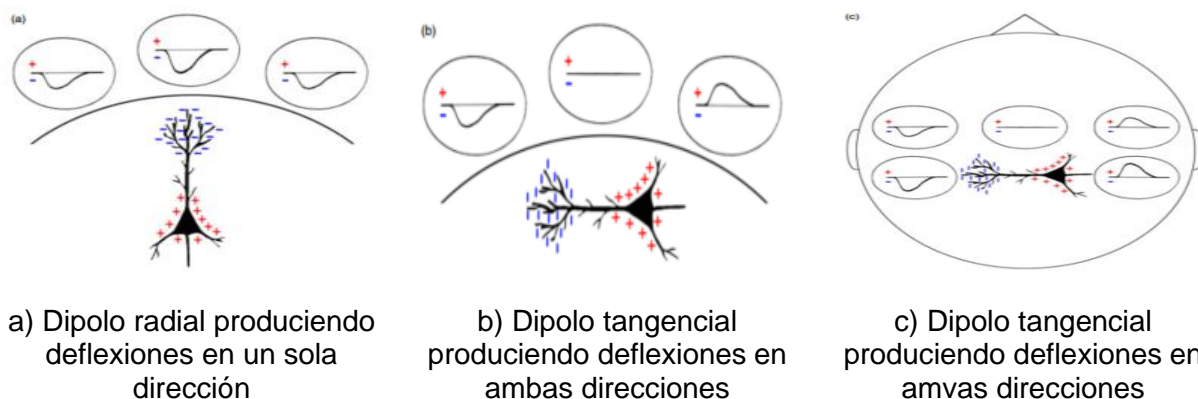


Figura 2.2 Medición de dipolos radiales y tangenciales. Fuente: (Jackson & Bolger, 2014).

Ahora de acuerdo con (Jackson & Bolger, 2014) debido a la naturaleza una sola neurona es demasiado pequeño para ser medido desde el cuero cabelludo. Sin embargo, dado que los electrodos detectan una suma de cargas en su entorno, los dipolos de múltiples neuronas en una región se suman entre en sí. La suma de varios dipolos individuales en un área es medible como un único dipolo, cuya magnitud refleja el número de neuronas cuyos dipolos se están sumando. Sin embargo, debido a que los electrodos medirán la suma de ambos extremos tanto positivos como negativos. De los dipolos en el cerebro, para producir una señal medible (no nula), las neuronas deben estar dispuestas como se muestra en la Figura 2.3 **Error! Reference source not found.** (a) y activas de forma sincrónica como se muestra en la Figura 2.3 (b). La disposición de las neuronas es necesaria para producir un dipolo medible, ya que, si las neuronas están alineadas en la misma orientación, sus señales pueden sumarse para formar una señal más grande. En cualquiera otra configuración, los extremos positivo y negativo de los dipolos individuales se cancelarán entre sí. La sincronización de la actividad es necesaria para generar una carga neta en el lado del dipolo orientado hacia el cuero, en lugar de que las cargas se cancelen entre sí, y una señal lo suficientemente grande como para poder ser medida.




Figura 2.3 Disposición paralela y la actividad sincrónica que permite que la señal sea medida en el cuero cabelludo. Fuente: (Jackson & Bolger, 2014). a: Las señales negativas se sumaran y

serán medibles en el cuero cabelludo. b: Las señales positivas y negativas se cancelarán entre sí en el cuero cabelludo, por lo tanto no serán medibles. c: No surge un dipolo claro de la disposición aleatoria de las cargas positivas y negativas, por lo que no se medirá ninguna señal en el cuero cabelludo.

La polaridad de la señal medida en el cuero cabelludo que de acuerdo con la Figura 2.4 también depende de la orientación particular del dipolo.




Figura 2.4 El EEG medido no puede determinar si la actividad es excitatoria o inhibitoria. Fuente (Jackson & Bolger, 2014).

Para ello se consideremos el caso de un potencial postsináptico excitador (EPSP) en una dendrita apical. Cuando se desencadena un EPSP en una sinapsis dendrítica, el fluido extracelular local se vuelve más negativo con respecto al fluido intracelular, ya que la corriente despolarizante fluye hacia el interior de la neurona. Esa corriente fluye hacia afuera en otras partes de la neurona, lo que produce una positividad extracelular local, aunque más distribuida.

De la Figura 2.4 la neurona de la izquierda está recibiendo un IPSP el cual produce una positividad extracelular cerca del soma o un EPSP que produzca una negatividad extracelular en las dendritas apicales. Cualquiera de estas señales se medirá como una deflexión negativa en el EEG. Ahora la neurona ubicada a la derecha está recibiendo un EPSP cerca del soma o un IPSP en las dendritas apicales. Cualquiera de estas señales se medirá como una deflexión positiva en el EEG.

2.3 ¿Cómo el EEG viaja desde el cerebro hasta el dispositivo de registro?

2.3.1 Dentro del cerebro

De acuerdo con (Jackson & Bolger, 2014) la conducción de volumen es responsable de la propagación de la señal EEG dentro del cerebro. La conducción de volumen es el proceso mediante el cual un grupo de iones repele a los iones cercanos que no tienen la misma carga. Estos iones repelidos, a su vez, repelen a otros iones con la misma carga, lo que resulta en una onda de carga que viaja a través del espacio extracelular. En el caso de un volumen homogéneo, esta onda de iones cargados puede propagarse a través del volumen sin impedimentos. Si las corrientes pudieran viajar sin

obstáculos a través de la corteza, el resultado sería una cascada de potenciales de acción disparándose sin especificidad. Es por ello que el cerebro produciría eventos de convulsión constantes. Sin embargo, el cerebro no es un volumen homogéneo. Los iones no pueden viajar a través de los tractos nerviosos recubiertos de mielina ni otros obstáculos físicos. Diferentes densidades de tejidos pueden impedir o permitir el flujo de iones, según sus propiedades eléctricas inherentes y su disposición física. Además, los dipolos no son todos del mismo tamaño, una señal proveniente de un dipolo grande puede viajar mucho más lejos que una señal de un dipolo pequeño.

2.3.2 Del cerebro al electrodo

Para ser medida la señal EEG con electrodo fuera de la cabeza, de acuerdo con lo expuesto por (Jackson & Bolger, 2014) la señal eléctrica creada por la actividad neuronal debe viajar desde el cerebro, a través de las capas duramadre, el cráneo, el cuero cabelludo y finalmente hasta el electrodo. Una vez que la señal conducida por volumen alcanza el borde del volumen a través del cual viaja, la conducción por volumen ya no puede ocurrir, ya que los iones no pueden salir de dicho volumen. Entre los volúmenes, una forma de capacitancia se vuelve responsable de la propagación de la señal tal como se muestra en la Figura 2.5. Debido a que el gel es un conductor, la señal llega al electrodo con menos atenuación de la que ocurriría si el gel no estuviera presente. Un capacitor en su forma más general consiste en dos grupos de cargas separadas por una capa aislante (un dieléctrico). La capa aislante evita que los iones se mezclen, si no estuviera la capa aislante, entonces puede acumularse una diferencia de carga a través de la capa, donde los iones negativos se empujan contra un lado de la membrana y los iones positivos se acumulan en el otro lado. La cantidad de carga que se acumula en el otro lado está determinada por las propiedades de los materiales aislantes entre los grupos de cargas, el tamaño del grupo cargado, y la distancia entre la carga y la capa aislante. La secuencia de capas desde el cerebro hasta las capas de la duramadre, las capas del cráneo, las capas del cuero cabelludo, el gel del electrodo y electrodo forman una serie de volúmenes conductores separados por capas aislantes, similar a una pila de capacitores.




Figura 2.5 La pila de capacitores con del de electrodo, mostrando la propagación de la señal neuronal a través de las capas del cerebro, duramadre, caneo y gel del electrodo hasta llegar al electrodo. Fuente: (Jackson & Bolger, 2014).

2.3.3 Fundamentos de EEG

De acuerdo con (Shahbakhti, 2020) las señales EEG recogidas pueden interpretarse de acuerdo con las cuatro áreas de la corteza (lóbulos) tal como se muestra en la Figura 2.6. Cada lóbulo tiene tareas específicas como se enlistan a continuación:

- O: lóbulo occipital (principalmente responsable del procesamiento de la información visual).
- P: lóbulo parietal (principalmente responsable de las funciones motoras).
- T: lóbulo temporal.
- F: lóbulo frontal (básicamente responsable de las funciones ejecutivas).




Figura 2.6 Lóbulos del cerebro

2.3.4 Sistema 10-20

De acuerdo con el autor (Tandle et al., 2016) en 1929, el psiquiatra alemán Hans Berger registró las señales cerebrales de los humanos. Utilizó el término electroencefalograma para referirse a las señales cerebrales. Posteriormente en 1958, la Federación Internacional de Electroencefalografía y Neurofisiología Clínica adoptó una calibración para la ubicación de los electrodos llamada sistema de colocación de electrodos 10-20 (Quintero-Rincón et al., 2021; Tandle et al., 2016). Este sistema estandarizó la colocación física de los electrodos y las etiquetas de los electrodos en el cuero cabelludo. La cabeza humana se divide en diferentes lóbulos: central, temporal, posterior y occipital. Los electrodos colocados en el lado izquierdo de la cabeza reciben números impares y los del lado derecho reciben números pares (ver Figura 2.7). Los números 10 y 20 especifican la distancia entre los electrodos adyacentes, que es del 10% o 20% de la distancia total de adelante hacia atrás o de derecha a izquierda del cráneo. Cada electrodo se nombra según la ubicación del lóbulo y el hemisferio. Cabe destacar que no existe un lóbulo central (C), y se utiliza solo para identificar fines específicos. La letra Z se refiere al lugar del electrodo en la línea media. Los números pares e impares indican la ubicación de los electrodos en los hemisferios derecho e izquierdo, respectivamente.

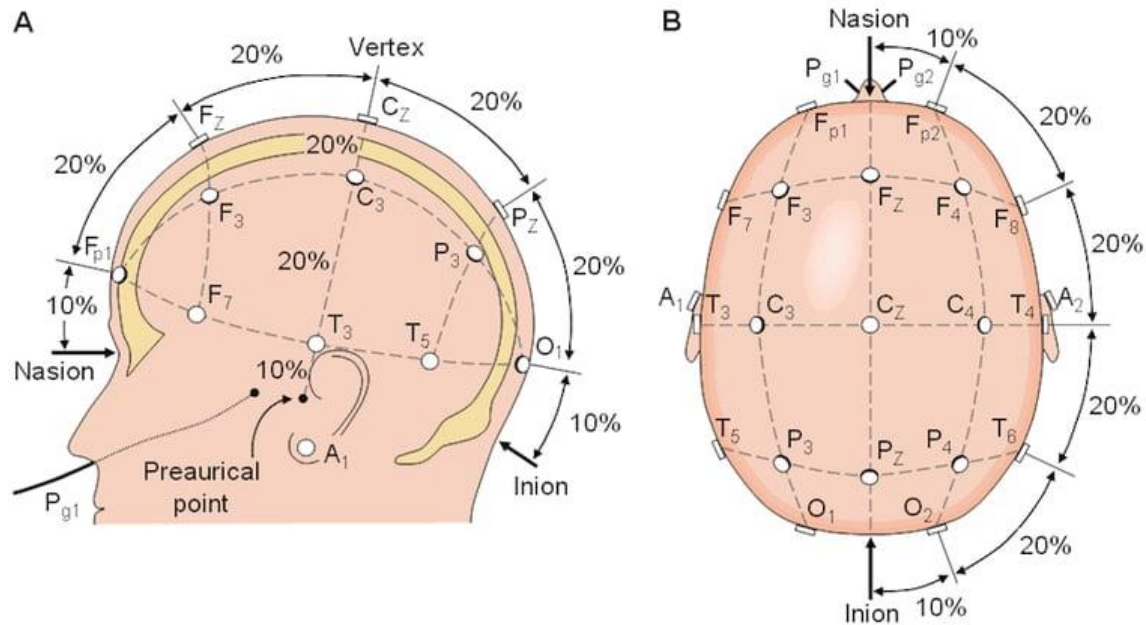


Figura 2.7 El sistema 10-20 con distancias entre electrodos de 10% y 20% de adelante hacia atrás (del nasion al inion).

2.3.5 Características de las señales cerebrales

De acuerdo con (Hu & Zhang, 2019b; Sanei & Chambers, 2007) las señales registradas EEG desde el cuero cabelludo varía entre 1 y 200 milivoltios, y su rango de frecuencia oscila entre 0.5 y 50 Hz. Las oscilaciones cerebrales se han clasificado en cinco ritmos:

- Delta (0.5 a 3.5 Hz): tiene la oscilación más lenta y la amplitud más alta (hasta 200 milivoltios).
- Theta (3.5 a 7 Hz): tiene una oscilación relativamente lenta y alta amplitud (hasta 100 milivoltios).
- Alpha (7 a 14 Hz): presenta una amplitud menor que Theta pero con fluctuaciones más rápidas.
- Beta (14 a 30 Hz): tiene una amplitud pequeña e irregular.
- Gamma (30 a 50 Hz): presenta las fluctuaciones más rápidas.

Las características de cada una de las oscilaciones se pueden ver en la Figura 2.8. Cabe mencionar que, durante una señal EEG continua, pueden estar presentes proporciones de todos estos ritmos, y estas proporciones pueden cambiar en relación con los procesos cognitivos y sensoriales.




Figura 2.8 Una señal EEG y las bandas correspondientes

2.3.6 Tipos de artefactos en EEG

En términos generales, los artefactos en EEG se pueden clasificar en dos tipos: fisiológicos y no fisiológicos. De acuerdo con (Bitbrain, 2020; Tandle et al., 2016) existe una clasificación de artefactos según su fuente de generación. Si la fuente es el cuerpo del sujeto, ese artefacto se llama artefacto fisiológico. Si la fuente es externa, se llama artefacto externo.

2.3.6.1 Artefactos fisiológicos

Los artefactos fisiológicos (ver Figura 2.9) son aquellos que se originan debido a la actividad eléctrica de otras partes del cuerpo del sujeto y oscurecen las señales del EEG. Los artefactos fisiológicos incluyen artefactos oculares, musculares y cardíacos (Jiang et al., 2019; Quintero-Rincón et al., 2021).

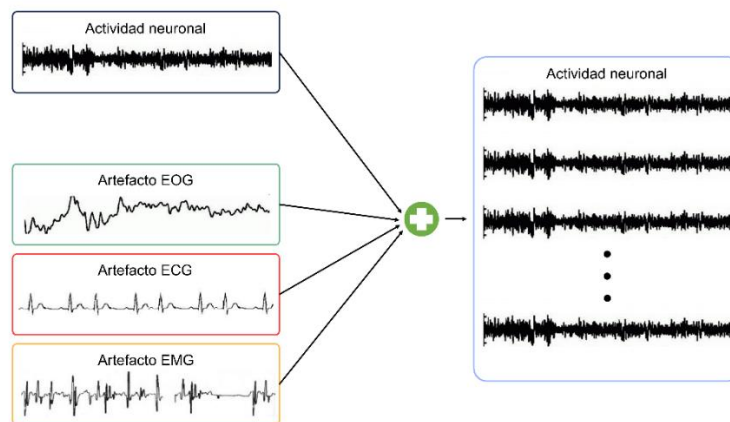


Figura 2.9 Artefactos y su interferencia en la señal EEG

2.3.6.1.1 *Artefactos de los ojos y los parpados*

El movimiento de los ojos y los globos oculares provoca un cambio de potencial en los electrodos cercanos a los ojos en Fp1-Fp2 (Fronto-Parietal). El parpadeo de los párpados aparece como una señal de 3Hz a 10Hz.

2.3.6.1.2 *Artefactos por movimiento ocular.*

El electroretinograma es una diferencia de potencial entre la retina y la córnea del ojo, y con la luz incidente, cambia, causando artefactos en las señales del EEG. La amplitud de voltaje es proporcional al ángulo de la mirada.

2.3.6.1.3 *Parpadeo de ojo*

Los parpadeos producen señales de alta amplitud que pueden ser muchas veces mayores que la amplitud de las señales de EEG de interés. Los parpadeos repetitivos producen ondas lentas que se parecen a ondas delta.

Tabla 2.1 Actividad ocular

Origen	El ojo puede modelarse eléctricamente como un dipolo magnético, que distorsiona el campo eléctrico de la región cuando se mueve.
¿Por que afecta al EEG?	Esta distorsión se conoce como la señal EOG (Electrooculograma) y tiene una amplitud generalmente un orden de magnitud mayor que la señal EEG, alcanzando valores de alrededor de 100-200 microvoltios.
Tipos de efectos	Parpadeo, movimiento lateral, movimientos oculares.
Efecto en el dominio temporal	El parpadeo produce un cambio rápido con alta amplitud en las señales EEG, principalmente en los electrodos de la zona frontal, siendo más pronunciado en aquellos más cercanos a los ojos. Los movimientos laterales del ojo también afectan las áreas frontales, pero son más significativos cuanto más cerca están de las sienes. En general, la amplitud del artefacto es casi proporcional al ángulo de la mirada.
Efecto en el dominio de la frecuencia	Efecto en frecuencias bajas que pueden confundirse con las bandas delta y theta.




Figura 2.10 Los picos de voltaje de alta amplitud (parpadeos) que afectan principalmente a los electrodos frontales (F7, Fpz, F8) y el aumento de potencia en frecuencias bajas (bandas delta y theta).




Figura 2.11 El efecto en F7 y F8, con cambios rápidos en la amplitud y diferentes direcciones como resultado del dipolo creado por el ojo en los sensores (este artefacto también se denomina inversión de fase, ya que el artefacto puede imitar un cambio de fase). Mayor potencia en frecuencias bajas (bandas delta y theta).

2.3.6.1.4 Artefactos musculares

Los artefactos musculares se clasifican como glossokinéticos (movimiento de masticar, movimiento de la lengua, tragar, hacer muecas, masticar), observados en los electrodos de superficie en EEG. La forma depende del grado de contracción muscular: una contracción débil produce una serie de picos de baja amplitud. Ocurren menos durante el sueño y se superponen con la banda beta (15-30Hz). Aparecen más comúnmente en los electrodos frontales y temporales.

Tabla 2.2 Actividad muscular

Origen	Los músculos producen actividad eléctrica cuando se contraen. Esta actividad puede medirse y la señal resultante se denomina electromiografía (EMG).
¿Por que afecta al EEG?	La actividad eléctrica generada por los músculos puede interferir con la actividad real del EEG. Estos artefactos de alta frecuencia pueden observarse a simple vista.
Tipos de efectos	Apretar la mandíbula, tensión en los músculos del cuello y los hombros, tragar, masticar, hablar, succionar, olfatear, hacer muecas, fruncir el ceño o tener hipo.
Efecto en el dominio temporal	Se observa una señal de alta frecuencia que se superpone a la señal EEG. La amplitud está correlacionada con la fuerza de la contracción muscular.
Efecto en el dominio de la frecuencia	Efecto en frecuencias altas, superponiéndose a los artefactos en las bandas beta y gamma del EEG.




Figura 2.12 El artefacto de alta frecuencia que ocurre al apretar la mandíbula. En este ejemplo, el efecto principal es observable en C3. Mayor potencia en frecuencias altas (bandas beta y gamma).

2.3.6.1.5 Artefactos cardiacos

El corazón produce dos tipos de artefactos: artefactos mecánicos y eléctricos, que aparecen como señales de ECG cerca de la región temporal izquierda y se ven más comúnmente en sujetos con cuellos cortos. Este artefacto eléctrico aparece como una

forma de onda de ECG registrada desde el cuero cabelludo. La mayoría de las frecuencias de los artefactos cardíacos están cerca de 1Hz y la amplitud está en varios milivoltios.

Tabla 2.3 Actividad muscular

Origen	Actividad eléctrica del corazón. Esta señal se conoce como electrocardiograma (ECG) y también se denomina artefacto de pulso.
¿Por que afecta al EEG?	Aunque la amplitud del ECG es baja en el cuero cabelludo, a veces, dependiendo de la ubicación del electrodo o la forma del cuerpo del participante, se puede observar una distorsión rítmica en las señales EEG.
Tipos de efectos	Actividad cardíaca, pulso.
Efecto en el dominio temporal	Un patrón rítmico, correspondiente a los latidos del corazón, que se superpone a la señal EEG.
Efecto en el dominio de la frecuencia	Los componentes de frecuencia del ECG se superponen a las bandas de frecuencia del EEG, por lo que es difícil visualizarlos a simple vista.

2.3.6.2 *Artefactos no fisiológicos*

Los artefactos no fisiológicos incluyen el desplazamiento de electrodos, interferencias del entorno y artefactos de movimiento. Estos artefactos pueden reducirse en número mediante instrucciones adecuadas al sujeto y un montaje experimental correcto.

2.3.6.2.1 *Artefacto de líneas de transmisión*

Como el ancho de banda de la señal EEG es de 0.5Hz-60Hz y la frecuencia de las líneas de transmisión es de 50Hz o 60Hz, la señal fácilmente se mezcla con la banda beta de la señal EEG. Este artefacto afecta todos los canales o aquellos con un mal ajuste de impedancia. Este artefacto se puede eliminar fácilmente utilizando un filtro de muesca en el rango de frecuencia de 50 Hz o 60 Hz.




Figura 2.13 La señal de alta frecuencia superpuesta a los datos EEG en todos los canales. Aparece un pico claro a 50 Hz. El EEG se registró en España y la frecuencia de la línea de energía es de 50 Hz.

2.3.6.2.2 Artefacto de teléfono

Este artefacto se debe a la señal de los teléfonos móviles. Una señal de alta frecuencia aparece como una señal espuria en las señales EEG. La solución para este artefacto es no llevar un teléfono móvil durante la grabación.

2.3.6.2.3 Artefacto de electrodo

Un mal contacto del electrodo da lugar a artefactos de baja frecuencia, que son transitorios breves limitados a un electrodo y se sincronizan con la respiración debido al movimiento del electrodo.

Tabla 2.4 Actividad electrodo

Origen	Canal de referencia no colocado o mal contacto en el canal de referencia.
¿Por que afecta al EEG?	La señal registrada no es EEG.
Tipos de efectos	Sensor de referencia no colocado.
Efecto en el dominio temporal	Cambios abruptos en todos los canales con alta amplitud. Todos los canales convergerán lentamente (efectos de filtrado) hacia las señales EEG reales cuando la referencia se coloque correctamente.
Efecto en el dominio de la	Potencia muy alta en todos los canales, y en señales no relacionadas con el EEG.

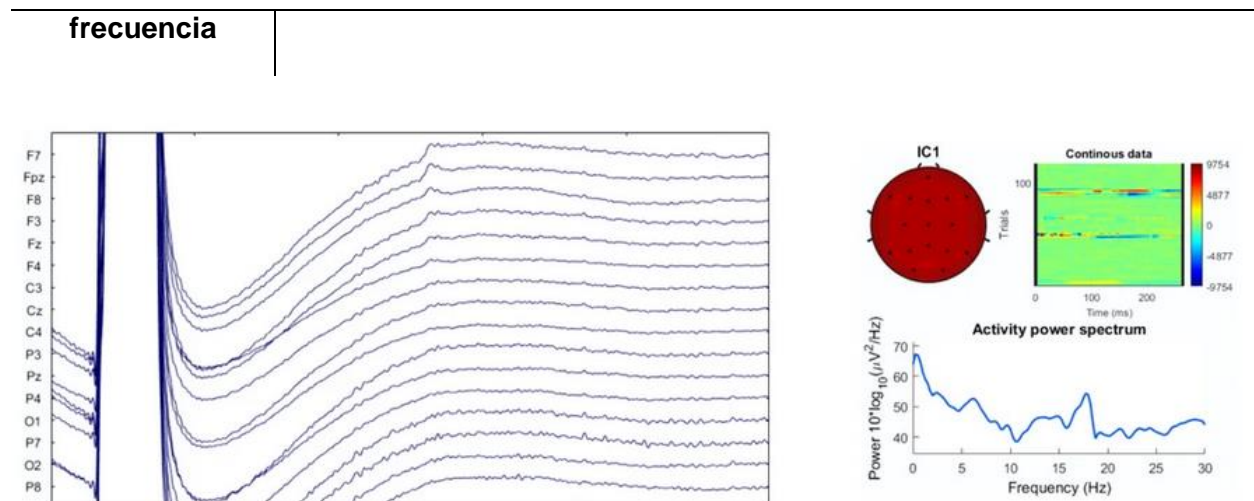


Figura 2.14 el cambio abrupto de alta amplitud en todos los canales cuando se retira la referencia, que lentamente converge hacia las señales EEG reales cuando se vuelve a colocar. Potencia muy alta en todas las frecuencias y un campo topográfico lógico de que cubre toda la cabeza.

2.3.6.2.4 Artefacto de "pop" del electrodo

Aparece como transitorios de contorno agudo que interrumpen la actividad de fondo y pueden interpretarse erróneamente como un tumor.

Tabla 2.5 Actividad electrodo

Origen	Fallos temporales en el contacto entre el sensor EEG y el cuero cabelludo, causados por tocar el sensor o por cambios espontáneos en el contacto entre el electrodo y la piel.
¿Por que afecta al EEG?	Fallos temporales en el contacto entre el sensor EEG y el cuero cabelludo, causados por tocar el sensor o por cambios espontáneos en el contacto entre el electrodo y la piel.
Tipos de efectos	"Electrode pop" (estallido de electrodo).
Efecto en el dominio temporal	Interferencia abrupta y generalmente de alta amplitud en la señal EEG, usualmente localizada en un solo canal.
Efecto en el dominio de la frecuencia	La caracterización de un "electrode pop" es difícil debido a la amplia gama de posibles distorsiones.




Figura 2.15 La distorsión en F3 producida al tocar el sensor. El efecto en el dominio temporal y de frecuencia depende del tipo de "pop" (tocar, espontáneo, etc.). En este caso, se pueden ver las frecuencias del artefacto producido por tocar en F3.

2.3.6.2.5 Artefacto por movimiento del cable

El movimiento del cable tiene una morfología más desorganizada que no parece actividad EEG real en ninguna forma e incluye a menudo una inversión de fase doble, es decir, inversiones de fase sin la uniformidad en la polaridad que indica un campo eléctrico generado cerebralmente.

Tabla 2.6 Actividad de movimiento de cable

Origen	Movimiento de los cables que conectan los electrodos con el sistema de amplificación.
¿Por que afecta al EEG?	Los cambios en los campos electromagnéticos producen distorsiones en la señal registrada, así como en el contacto entre el cuero cabelludo y el sensor.
Tipos de efectos	Movimiento del cable, toque del cable.
Efecto en el dominio temporal	Depende mucho del tipo de movimiento del cable. Si el movimiento es rítmico, aparecerán distorsiones superpuestas a las señales EEG con el mismo ritmo del movimiento del cable.
Efecto en el dominio de la frecuencia	También depende del tipo de movimiento. Si los movimientos son rítmicos, podemos encontrar picos de frecuencia no relacionados con el EEG.




Figura 2.16 En este ejemplo, aparece una distorsión en Cz o Pz al mover los cables. Como se mencionó antes, el efecto en el dominio temporal y de frecuencia puede variar mucho según el movimiento del cable y los cambios en el contacto entre el sensor y el cuero cabelludo.

2.3.6.2.6 Artefacto por transpiración

El artefacto por transpiración se manifiesta como ondas de baja amplitud y duración mayor a 2 segundos; por lo tanto, están fuera del rango de frecuencia generado cerebralmente en el EEG.

2.3.6.2.7 Artefacto por movimiento físico

Este artefacto aparece debido al mal contacto del electrodo por un movimiento físico abrupto del sujeto. Su morfología es diferente de la actividad EEG real.

Tabla 2.7 Actividad de movimiento del cuerpo

Origen	Movimientos corporales, principalmente los movimientos de la cabeza.
¿Por que afecta al EEG?	Al moverse, incluso de manera no intencional, se altera el contacto entre el electrodo y la piel, lo que corrompe la señal EEG.
Tipos de efectos	Movimientos de la cabeza, movimientos de los brazos, caminar, correr.
Efecto en el dominio temporal	Olas lentas temporales que corresponden al ritmo del movimiento.
Efecto en el dominio de la frecuencia	El efecto se localiza en frecuencias bajas, superponiéndose a las bandas delta y theta.




Figura 2.17 El efecto del movimiento de la cabeza superpuesto a los datos EEG en todos los canales. El efecto de los movimientos se superpone a las frecuencias bajas del EEG.

2.4 Aplicaciones de las señales de Electroencefalograma

De acuerdo con (Mannan et al., 2018) el electroencefalograma tiene ventajas de ser portátil, de bajo costo y tener una alta resolución temporal, es una modalidad de imagen cerebral no invasiva que puede usarse para medir diferentes estados cerebrales. La no invasividad, portabilidad, bajo costo y alta resolución temporal hacen que el EEG sea el método de imagen cerebral más preferido. Mide la actividad eléctrica conjunta de una población de neuronas con una amplitud típicamente en el orden de unos pocos microvoltios. Estas ventajas lo hacen ideal para estudiar enfermedades como la enfermedad de Alzheimer y la esquizofrenia. Hoy en día, el EEG se utiliza ampliamente en muchos campos como la neurociencia, la psicología, la ciencia cognitiva y la investigación psicofisiológica. El EEG también se usa extensamente en la investigación clínica para el diagnóstico e identificación de muchas condiciones cerebrales, como trastornos del sueño, depresión, actividad epiléptica y demencia. Todas estas aplicaciones de monitoreo EEG son posibles debido a que los dispositivos requieren poca o ninguna supervisión y su instalación es sencilla, incluso para personal sin conocimientos técnicos. El inconveniente de operar en estas condiciones diversas e incontroladas es la posible contaminación de la señal por fuentes externas. Esto es especialmente común en dispositivos que operan en unidades de cuidados intensivos, unidades de monitoreo de epilepsia o quirófanos. Dado que la intensidad de la señal en el EEG de cuero cabelludo es débil (típicamente de $20\mu\text{V}$ a $100\mu\text{V}$ de amplitud en adultos), incluso pequeñas variaciones en la señal eléctrica pueden producir artefactos visibles en los trazados EEG. Ejemplos de estos artefactos incluyen movimientos oculares y parpadeos, actividad muscular o cardíaca, movimiento de los electrodos o cables, transpiración de la piel e interferencias causadas por dispositivos eléctricos como marcapasos. Aunque los artefactos pueden ser identificados y eliminados mediante inspección visual cuando el análisis se realiza offline por especialistas, presentan un problema importante en los dispositivos de monitoreo que operan en tiempo real y sin supervisión. En la mayoría de los casos, los artefactos pueden detectarse de manera confiable localizando altos voltajes o frecuencias no fisiológicas. Típicamente, los dispositivos de monitoreo clínico incluyen detección de artefactos y solucionan el problema suspendiendo temporalmente el monitoreo y reanudándolo solo cuando la

proporción de señal con artefactos cae por debajo de un umbral establecido. Durante la anestesia, esta interrupción priva al personal médico de información relevante y puede retrasar la toma de decisiones. Por lo tanto, es deseable asegurar la continuidad del monitoreo incluso en presencia de artefactos.

2.5 Tipos de transformadas en análisis de señales

En el caso de una señal EEG, las señales son no estacionarias, es decir, el espectro varía con el tiempo. Durante su adquisición se generan diferentes bandas de frecuencias diferentes en cada instante.

2.5.1 Transformada de Fourier

De acuerdo con la definición que nos proporciona los autores (Goyal & Pabla, 2015) la Transformada de Fourier (FT) es una representación en el dominio de la frecuencia que aproxima la efectividad de los diferentes componentes de frecuencia (el espectro de potencia) de una señal en el dominio del tiempo. La Transformada de Fourier directa se utiliza para convertir la señal del dominio del tiempo al dominio de la frecuencia, y la Transformada de Fourier inversa se emplea para convertirla nuevamente del dominio de la frecuencia al dominio del tiempo.

La Transformada de Fourier directa se expresa como:

$$F(\omega) = Ff(t) = \sum_{t=0}^{N-1} f(t)e^{-i\omega t} \quad (2.1)$$

La Transformada de Fourier inversa se expresa como:

$$F(\omega) = F^{-1}(F(\omega)) = \frac{1}{2\pi} \sum_{t=0}^{N-1} F(\omega)e^{i\omega t} \quad (2.2)$$

La Transformada Rápida de Fourier es uno de los métodos más utilizados y antiguos para obtener la Transformada de Fourier de señales temporales discretizadas. También se considera una técnica de diagnóstico más efectiva y eficiente debido a que se puede aplicar fácilmente y analiza señales estacionarias. Esta señal se estudia durante un tiempo finito, denominado ventana de tiempo, que luego se digitaliza y se almacena para la extracción de características. La elección de una tasa de muestreo adecuada es importante para la digitalización de la señal, evitando así componentes de frecuencia falsas que ocurren debido al aliasing. Según el teorema de Nyquist, la frecuencia de muestreo debe ser al menos el doble de la frecuencia máxima presente en la señal. Por otro lado, de acuerdo con (Goyal & Pabla, 2015) menciona que la Transformada de Fourier presenta limitaciones significativas, ya que no puede representar los cambios espectrales por ejemplo de una vibración, voz o señales biomédicas a lo largo del tiempo por lo tanto no puede aplicarse para monitorear estructuras reales sometidas a excitaciones dinámicas. Es por ello que se utiliza la técnica de análisis conjunto tiempo-frecuencia para caracterizar una señal simultáneamente en una representación bidimensional (tiempo versus frecuencia). La principal diferencia entre cada método tiempo-frecuencia radica en cómo se maneja el problema de la incertidumbre. El principio

de incertidumbre establece que "no se puede tener simultáneamente una buena resolución en frecuencia y una buena resolución en tiempo". Para superar el problema de la pérdida de información temporal se describen tres técnicas de procesamiento de señales en las siguientes secciones: Transformada de Fourier de Tiempo Corto (STFT), Transformada Hilbert y Transformada Wavelet (TW).

2.5.1.1 Transformada de Fourier de Tiempo Corto Discreta

De acuerdo con (Goyal & Pabla, 2015) la Transformada de Fourier de Tiempo Corto (STFT) se introduce para superar las limitaciones de la Transformada Rápida de Fourier (FFT). Normalmente, se utiliza para la extracción de contenido de frecuencia de banda estrecha en señales no estacionarias o ruidosas. La idea básica de la STFT es dividir la señal inicial en pequeñas ventanas de tiempo y aplicar la Transformada de Fourier a cada segmento de tiempo para expresar la variación en el contenido de frecuencia de la señal a lo largo del tiempo en ese segmento (ver Figura 2.18).




Figura 2.18 Transformada de Fourier en Tiempo Corto

La STFT ofrece un análisis con ancho de banda absoluto constante para identificar componentes armónicos y proporciona una resolución constante en la representación bidimensional, independientemente de la frecuencia real. La ecuación matemática para la Transformada de Fourier de Tiempo Corto se expresa como:

$$s_{f,\tau} = \sum_{\tau=0}^{N-1} x(t)\omega(t - \tau) e^{-j2\pi f\tau} \quad (2.3)$$

donde $x(t)$ es la señal que se está analizando y $\omega(t)$ es la función ventana centrada en el tiempo τ . Actualmente, el espectrograma de Fourier (es decir, la amplitud al cuadrado $|S(f, \tau)|^2$) se muestra en un diagrama de tiempo-frecuencia. Lamentablemente, la ventana fija utilizada en la STFT implica una resolución fija tanto en el dominio del tiempo como en el dominio de la frecuencia. El problema radica en que la precisión para obtener información de frecuencia está limitada por la longitud de la ventana en comparación con la duración de la señal de interés.

La STFT tiene la limitación de baja resolución. Este problema surge al elegir una ventana pequeña, lo que no permite capturar adecuadamente el comportamiento transitorio dinámico de la estructura. El tamaño de la ventana determina la precisión temporal: cuanto mayor es la ventana, peor es la resolución temporal pero mejor la resolución en frecuencia, y viceversa. Además, la STFT no permite observar frecuencias naturales cercanas entre sí.

2.5.1.2 Inversa de la Transformada de Fourier de Tiempo Corto Discreta

Para obtener la Inversa de la Transformada de Fourier de Tiempo Corto (STFT), utilizamos la misma ventana y el mismo proceso de segmentación que en la STFT directa. La idea es reconstruir la señal original $x(t)$ a partir de la representación tiempo-frecuencia $S(f, \tau)$.

Para recuperar $x(t)$ a partir de $S(f, \tau)$ aplicamos la IDFT para recuperar $s(\tau, t)$, que es el segmento de señal en la ventana τ :

$$s(\tau, t) = IDFT\{S(f, \tau)\} \quad (2.4)$$

donde la multiplicación $S(f, \tau)$ por la misma ventana utilizada en la STFT directa, desplazada por el centro de la ventana τ :

$$s(\tau, t) \cdot \omega(t - \tau) \quad (2.5)$$

Finalmente la suma de bloques solapados para obtener la señal reconstruida $y(t)$ es:

$$y(t) = \sum_{\tau} s(\tau, t) \cdot \omega(t - \tau) \quad (2.6)$$

La reconstrucción será exacta ($y(t) = x(t)$) solo si la función ventana $\omega(t)$ se elige adecuadamente. Si la ventana no se selecciona correctamente, la señal reconstruida $y(t)$ no coincidirá con la señal original $x(t)$. El uso de una ventana inapropiada puede resultar en errores de reconstrucción, ya que afecta la precisión tanto en el dominio del tiempo como en el dominio de la frecuencia.

2.5.1.3 Transformada Wavelet

En 1982, Jean Morlet introdujo el concepto de análisis tiempo-frecuencia de alta resolución, que se ha convertido en una de las herramientas matemáticas y de procesamiento de señales emergentes y de rápida evolución en los últimos 10 años. Esta técnica logra un equilibrio óptimo entre la resolución en frecuencia y la resolución en tiempo para el análisis de ondas sísmicas. A diferencia de la STFT, la Transformada Wavelet (WT) consiste en una familia de funciones elementales (en función del tiempo) utilizadas para el análisis multiescala de una señal, que pueden dilatarse y desplazarse de forma independiente, conocidas como wavelets.

2.5.1.4 Transformada wavelet continua

La Transformada Wavelet Continua (CWT) nos permite examinar una señal en diferentes escalas y posiciones. Matemáticamente, se representa como:

$$CWT_x(a, b) = \int_{-\infty}^{\infty} x(t) \cdot \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) dt \quad (2.7)$$

donde:

- $x(t)$ es la señal de entrada.
- ψ es la función wavelet.
- a es el factor de escala, que proporciona información sobre el componente de frecuencia.
- b es el factor de traslación, que permite la localización en el tiempo.

A medida que se ajusta el aumento (escala a), se puede hacer zoom en partes específicas de la señal, y al mover (traslación b), se puede examinar diferentes instantes de tiempo.

2.5.1.5 Transformada wavelet discreta

La Transformada Wavelet (WT) de una señal $x(t)$ se puede calcular a través de la frecuencia media de $x(t)$ si la frecuencia media de la función wavelet $c(t)$ es v_0 en $t = 0$, tal como se expresa mediante:

$$W(a, b) = |a|^{-1/2} \sum_{t=0}^{N-1} x(t) \psi^* \left(\frac{t-b}{a} \right) \quad (2.8)$$

donde $W(a, b)$ refleja el comportamiento de la señal en la vecindad de $(b, v_0/a)$, $c(t)$ es la wavelet madre, a es el factor de escala que dilata o contrae la wavelet $c(t)$, y b es el parámetro de desplazamiento que permite la traslación de las wavelets.

$$F\{W(a, b)\} = \frac{|a|^{-1/2}}{2\pi} \sum_{t=0}^{N-1} \left[x(t) \psi^* \left(\frac{t-b}{a} \right) \right] e^{-2j\pi f\tau} \quad (2.9)$$

el factor de escala de la TWD a se elige como una potencia de dos y generalmente se implementa mediante un par de filtros wavelet de paso bajo y paso alto.

Aunque la WT es similar a la STFT, la primera ofrece una mejor localización temporal en altas frecuencias y permite un análisis con ancho de banda porcentual (o relativo) constante. La WT es más adecuada para señales no estacionarias y permite un análisis tiempo-frecuencia adaptativo. La WT puede proporcionar información de amplitud y fase de las señales de manera sincrónica. Las wavelets complejas tienen la ventaja de no ser sensibles a la fase del evento que se está transformando, por lo que son muy útiles para la eliminación de ruido, ya que son compactas en el dominio de la frecuencia, pero infinitas en el dominio temporal.

2.5.1.6 ¿Qué es una wavelet?

De acuerdo con (Jake, 2023) a un nivel fundamental, una wavelet es una pequeña onda (ver Figura 2.19). El termino pequeña se utiliza para indicar que tiene una duración limitada. A diferencia de los senos y cosenos, que se extienden desde $-\infty$ hasta ∞ , las wavelets están localizadas en el tiempo, lo que otorga propiedades únicas ideales para ciertas aplicaciones. Matemáticamente, una wavelet debe cumplir con la siguiente condición:

$$\int_{-\infty}^{\infty} \psi(t), dt = 0 \quad (2.10)$$

Esto significa que la wavelet tiene áreas positivas y negativas iguales, lo que resulta en una media cero. A diferencia de la Transformada de Fourier, donde esta descompone una señal en sus componentes sinusoidales. Esta carece de localización temporal. Esto significa que, si ocurre un evento breve pero significativo en la señal, la Transformada de Fourier podría no capturarlo de manera efectiva. Aquí es donde entran las wavelets. Con su naturaleza localizada, las wavelets pueden capturar información tanto de frecuencia como de tiempo. Esta doble naturaleza las hace especialmente adecuadas para señales no estacionarias, donde las propiedades de la señal cambian con el tiempo.




Figura 2.19 Ejemplos de wavelets

2.5.1.7 Transformada wavelet discreta y coeficientes

De acuerdo con (Jake, 2023) aunque la CWT es continua por naturaleza, en el ámbito digital a menudo trabajamos con señales discretas. La Transformada Wavelet Discreta (DWT) proporciona un método computacionalmente eficiente para analizar señales a diferentes resoluciones. La DWT descompone una señal en dos conjuntos de coeficientes: coeficientes de aproximación (c_A) y coeficientes de detalle (c_D). Esta descomposición se logra utilizando dos conjuntos de funciones: funciones de escalado ($\phi(t)$) y funciones wavelet ($\psi(t)$). Dada una señal discreta $x[n]$, los coeficientes de la DWT en la escala s y la posición l se definen como:

- Coeficientes de Aproximación. Los coeficientes de aproximación representan la parte de baja frecuencia de la señal. Capturan la forma general o las características suaves de la señal y proporcionan información sobre su estructura global.

$$c_A[s, l] = \sum_n x[n] \phi\left(\frac{n - 2^s l}{2^s}\right) \quad (2.11)$$

- **Coefficientes de Detalle:** Los coeficientes de detalle representan la parte de alta frecuencia de la señal. Capturan cambios rápidos, bordes o detalles finos de la señal, proporcionando información sobre variaciones locales y características específicas.

$$c_D[s, l] = \sum_n x[n] \psi\left(\frac{n - 2^s l}{2^s}\right) \quad (2.12)$$

donde:

- s es el factor de escala. Incrementar s proporciona una vista más amplia y general de la señal (componentes de baja frecuencia).
- l es el factor de traslación, que determina la ubicación en la señal que se está analizando.
- a es el factor de escala, que proporciona información sobre el componente de frecuencia.
- Las funciones $\phi(t)$ y $\psi(t)$ se derivan de una wavelet seleccionada (por ejemplo, Daubechies, Haar).

El proceso de la DWT puede aplicarse iterativamente a los coeficientes de aproximación para lograr una descomposición multinivel. En cada nivel, los coeficientes de aproximación se descomponen aún más en un conjunto más fino de coeficientes de aproximación y detalle. Esta descomposición jerárquica permite realizar un análisis multirresolución de la señal. Los coeficientes de aproximación capturan la vista general, mientras que los coeficientes de detalle capturan las intrincaciones específicas.

2.5.1.1 Inversa de la Transformada Wavelet Discreta

El cálculo de la transformada inversa se utiliza para reconstruir la señal original a partir de los coeficientes de aproximación y detalle. La reconstrucción implica invertir los pasos del proceso de descomposición (análisis), que incluye filtrado y submuestreo.

$$c_{A_{j-1}}(n) = \sum_k (c_{A_j}(k) \cdot g(k - 2n) + c_{D_j}(k) \cdot h(k - 2n)) \quad (2.13)$$

Partiendo de los coeficientes de aproximación y detalle en el nivel j , c_{A_j} y c_{D_j} la transformada wavelet discreta inversa (IDWT) reconstruye c_{A_j} , invirtiendo el paso de descomposición al insertar ceros y convolucionar los resultados con los filtros de reconstrucción.

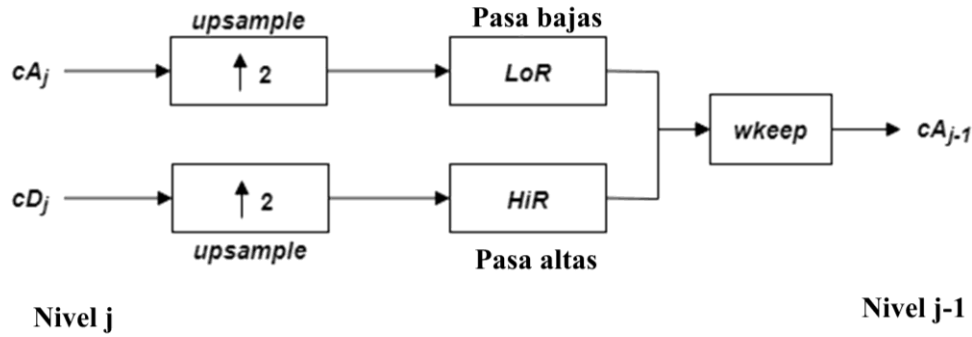



Figura 2.20 Transformada Wavelet Inversa

Donde:



Insertar ceros en elementos de índice par

Convolución con filtro x

Tome la parte central de U con la longitud conveniente

2.5.1.2 Transformada Hilbert-Huang

En 1905, el científico alemán David Hilbert introdujo por primera vez el operador de desfase $\pi/2$ como una propiedad fundamental de la transformada de Hilbert (Ahmadizadeh & Hemmati, n.d.; Huang, n.d.). La transformada de Hilbert $\tilde{x}(t)$ es una convolución entre el transformador de Hilbert $\frac{1}{(\pi t)}$ y una función $x(t)$ y se define como:

$$\tilde{x}(t) = H\{\tilde{x}(t)\} = x(t) * \frac{1}{\pi t} = \frac{1}{\pi} \sum_{\tau=0}^{N-1} x(\tau) \frac{1}{t-\tau} \quad (2.14)$$

La amplitud e instantánea y la fase instantánea se evalúan como:

$$|x(t)| = \sqrt{x^2(t) + \tilde{x}^2(t)} \quad (2.15)$$

$$\theta_i(t) = \tan^{-1} \left[\frac{\tilde{x}(t)}{x(t)} \right] \quad (2.16)$$

Teóricamente, una señal analítica puede expresarse como la suma de la parte real e imaginaria:

$$x_a(t) = x(t) + j\tilde{x}(t) \quad (2.17)$$

La Transformada Hilbert-Huang como una técnica patentada o adaptativa de procesamiento de señales basada en la descomposición modal empírica (EMD), para extraer las propiedades de señales estacionarias, no estacionarias y transitorias, especialmente para representaciones en el dominio tiempo-frecuencia-energía. El HHT se aplica en dos pasos:

- Primero, la EMD, que es la parte central del HHT, tiene la capacidad de descomponer adaptativamente cualquier serie temporal en funciones cuasi-estacionarias llamadas funciones modales intrínsecas (IMF). Estas funciones son una representación adaptativa, completa y casi ortogonal de la señal a ser analizada, y permiten el cálculo de una representación de frecuencia instantánea multicomponente.
- Segundo, el análisis espectral de Hilbert se aplica a estas IMF extraídas para obtener la energía local de cada frecuencia instantánea, o para obtener su amplitud y ángulo de fase a partir de señales no lineales o no estacionarias. El HHT ha sido utilizado para el análisis de señales de vibración en diversas áreas como ingeniería mecánica, biomedicina y tecnología de terremotos. Se ha aplicado en motores con grietas inducidas para interpretar la respuesta no lineal.

Aunque el HHT posee la ventaja de no requerir convolución, menor tiempo computacional y ser un método prometedor para extraer características de señales no lineales y no estacionarias, también presenta algunas limitaciones. En primer lugar, la EMD genera IMF indeseadas en la región de baja frecuencia, lo que puede llevar a una interpretación errónea de los resultados. En segundo lugar, no se puede lograr la propiedad monocomponente de las IMF obtenidas debido al amplio rango de frecuencias. En tercer lugar, la EMD no puede separar los elementos de señal de baja frecuencia. Por lo tanto, se requiere una técnica mejorada de HHT para resolver estas limitaciones.

2.6 Aprendizaje profundo en procesamiento de señales

En esta sección se describen los fundamentos de las redes neuronales profundas a implementar en este trabajo de tesis. Este apartado aborda a las redes neuronales adversarias generativas (GANs), las cuales se configuraron para resolver problemas de regresión y clasificación. Además, se detalla las redes neuronales que conforman a una GAN, como las redes neuronales convolucionales (CNN) y las redes de memoria a largo plazo bidireccionales (BLSTM).

2.6.1 Introducción al aprendizaje profundo.

Las redes adversarias generativas son usadas en el aprendizaje semi-supervisado y no supervisado. Este tipo de redes neuronales son dos arquitecturas de redes neuronales que se entrenan en competencia simultánea (Creswell et al., 2018). Las redes adversarias generativas están compuestas por un generador y un discriminador que aprenden simultáneamente (ver Figura 2.21). El generador aprende a generar muestras reales además de nuevas muestras de datos. El discriminador es un clasificador binario, que discrimina las muestras reales de las muestras generadas (Goodfellow et al., 2020). Las arquitecturas de redes que representan un generador y un discriminador se implementan mediante redes multicapa, que están compuestas por capas convolucionales y/o completamente conectadas. Las redes del generador y el discriminador deben ser diferenciables, aunque no es necesario que sean invertibles directamente (Creswell et al., 2018). El generador no tiene acceso directo a las muestras reales, su aprendizaje se produce a través de su interacción con el discriminador. El discriminador tiene acceso tanto a las muestras del generador además de contar con las muestras del conjunto de muestras reales. La propagación del error para el discriminador se proporciona con la información de saber si la muestra proviene del conjunto real o del

generador. La misma señal de error, a través del discriminador, se puede utilizar para entrenar el generador, llevándolo a ser capaz de producir falsificaciones de mejor calidad. Si consideramos que la red del generador mapea desde un espacio de representación, llamado espacio latente, hacia el espacio de los datos, podemos expresarlo de manera más formal como $G: G(z) \rightarrow R^{|x|}$, donde $z \in R^{|z|}$ es una muestra del espacio latente, $x \in R^{|x|}$ es una muestra, $|\cdot|$ y denota el número de dimensiones (Creswell et al., 2018). En una red adversaria generativa básica, la red del discriminador D se caracteriza de manera similar como una función que mapea los datos de imagen a una probabilidad de que la imagen provenga de la distribución de datos reales, en lugar de la distribución del generador: $D(x) \rightarrow [0,1]$. Para un generador fijo G , el discriminador D puede ser entrenado para clasificar imágenes como provenientes de los datos de entrenamiento (reales, cercano a uno) o del generador fijo (falso, cercano a cero). Cuando el discriminador es óptimo, se puede congelar o dejar de entrenar, y el generador G puede seguir siendo entrenado para reducir la precisión del discriminador. Si la distribución del generador logra coincidir perfectamente con la distribución de los datos reales, el discriminador estará máximamente confundido, prediciendo 0.5 para todas las entradas (Wang et al., 2017).




Figura 2.21 Red neuronal adversaria generativa



Capítulo 3

Método y propuesta de investigación

Capítulo 3 Método y propuesta de investigación

3.1 Modelo de investigación

La metodología adaptada para la identificación y eliminación de artefactos en señales EEG se compone de seis etapas, siguiendo un esquema similar al modelo científico descrito por Hernández et al. (2017). La propuesta se enfoca en abordar el problema de mejorar la calidad de las señales EEG mediante la identificación y eliminación de artefactos, utilizando técnicas de procesamiento de señales y aprendizaje profundo. En la etapa de formulación del problema se define claramente el problema a abordar: mejorar la calidad de las señales EEG mediante la identificación y eliminación de artefactos. El objetivo principal es desarrollar un modelo que detecte y elimine estos artefactos, mejorando así la calidad de las señales para su posterior análisis. En la etapa de revisión sistemática de la literatura lleva a cabo una revisión exhaustiva de la literatura científica para identificar las técnicas y arquitecturas de modelos más efectivas en la eliminación de artefactos de EEG. En la etapa de selección de técnicas de procesamiento se seleccionan las técnicas de procesamiento de señales más adecuadas para la eliminación de artefactos en EEG. Estas técnicas pueden incluir una combinación de métodos tradicionales y modelos de aprendizaje profundo. En la etapa cuatro del diseño de la arquitectura del modelo se diseña una arquitectura de modelo de aprendizaje profundo optimizada para la identificación y eliminación de artefactos en EEG. En la etapa cinco se realizará el desarrollo conceptual y experimental. Finalmente se lleva a cabo una validación y evaluación del modelo de identificación y eliminación de artefactos.

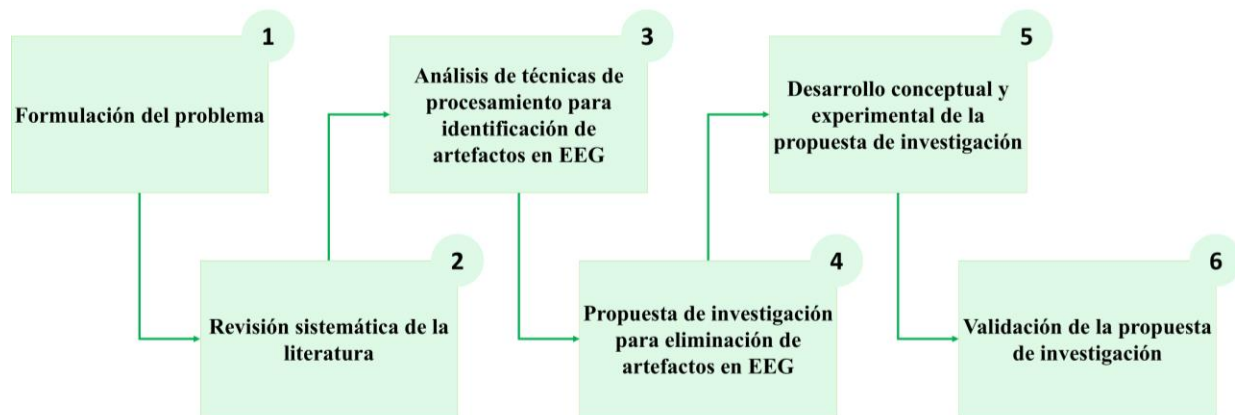


Figura 3.1 Modelo general de investigación

3.2 Propuesta de investigación a realizar

La Figura 3.2 muestra la propuesta de investigación para la eliminación de artefactos en señales EEG a través del uso de aprendizaje profundo y adaptación de dominio. A continuación, se describe cada paso del proceso representado en el diagrama:

a) Clasificación e identificación de artefactos en la señal EEG

- El primer paso consiste en identificar y clasificar los artefactos presentes en la señal EEG utilizando técnicas de aprendizaje profundo tales como la

- arquitectura YOLO-Like.
- Esta etapa puede incluir el uso de métodos automáticos para reconocer artefactos fisiológicos y no fisiológicos.
- b) Preparación del conjunto de datos
- Conjunto de datos EEG real: Se utiliza un conjunto de datos de EEG obtenido de experimentos reales el cual serán TUH EEG Artifact Corpus y EEGdenoiseNet.
 - Generación de señales sintéticas EEG: Se crean señales sintéticas para simular diferentes tipos de artefactos y aumentar la diversidad del conjunto de datos.
 - Añadir artefactos a la señal EEG sintética: Se introducen artefactos de forma controlada en las señales sintéticas para entrenar el modelo en la detección y eliminación de dichos artefactos.
- c) Preprocesamiento y análisis de características
- Preprocesamiento de la señal EEG: Incluye pasos como filtrado, normalización y segmentación de la señal para mejorar la calidad de los datos antes de su análisis.
 - Análisis y extracción de características: Se extraen características relevantes de la señal EEG para alimentar el modelo de aprendizaje profundo estas serán Señal en el dominio del Tiempo y en el dominio de las frecuencias usando transformadas tales como la transformada rápida en tiempo de corto de Fourier, Transformada Wavelet y Transformada Hilbert.
 - Modelo de aprendizaje profundo: Se implementarán modelos de aprendizaje profundo cuyos modelos se entrenarán para mejorar la señal EEG eliminando los artefactos detectados.
- d) Evaluación de la calidad de la señal EEG
- Se realiza una evaluación de la calidad de la señal mejorada, tanto para datos sintéticos como reales.
 - La evaluación compara el rendimiento del modelo con y sin la clasificación e identificación de artefactos, para validar su efectividad.
- e) Comparación con el estado del arte
- El modelo de aprendizaje profundo propuesto se evalúa y compara con métodos existentes, para determinar si ofrece una mejora significativa respecto al estado del arte.
- f) Generación de una herramienta (TOOLBOX)
- Como resultado final de la investigación, se desarrollará una herramienta o librería que permita la eliminación automática de artefactos en señales EEG.
 - Esta herramienta estará orientada a facilitar su uso en aplicaciones reales, como estudios clínicos o investigaciones en neurociencia.

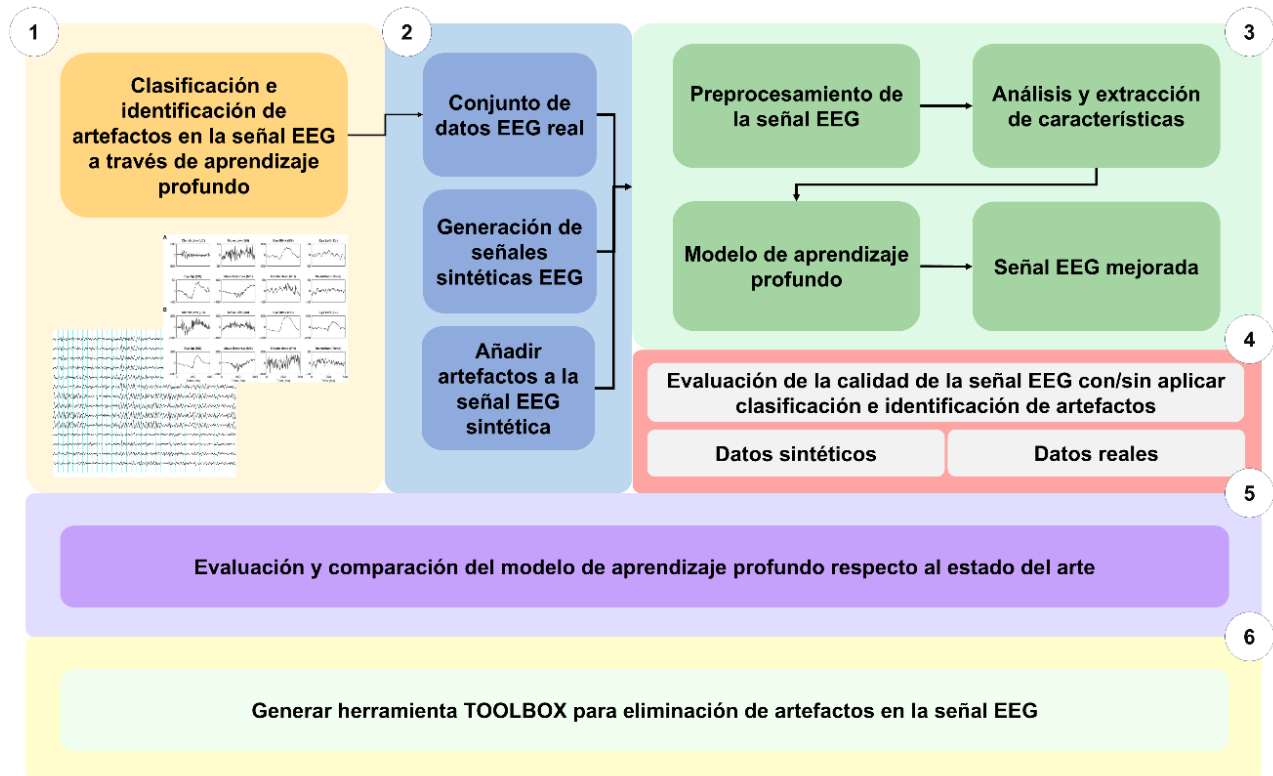


Figura 3.2 Propuesta de investigación

3.3 Descripción de los datos

3.3.1 Razones para simular datos EEG para probar métodos análisis

De acuerdo con (Cohen, 2022) el simular datos EEG es útil, y sus principales razones son:

- Validar métodos de análisis con datos de referencia (Ground Truth).
- Conocer las ventajas y limitaciones de los métodos de análisis.
- Comprender cómo funcionan los métodos de análisis.
- Comprender mejor los datos a analizar.
- Pensar de manera más cuidadosa y crítica sobre los datos.
- Mejorar las habilidades de pensamiento de lo que se requiere hacer.

3.3.2 Generación de datos sintéticos EEG

De acuerdo con (Cohen, 2022) plantea un algoritmo para crear una señal EEG sintética utilizando ruido filtrado en el dominio de la frecuencia, para luego transfórmala al dominio del tiempo. La Figura 3.3 ilustra los pasos a seguir para generar la señal de EEG.

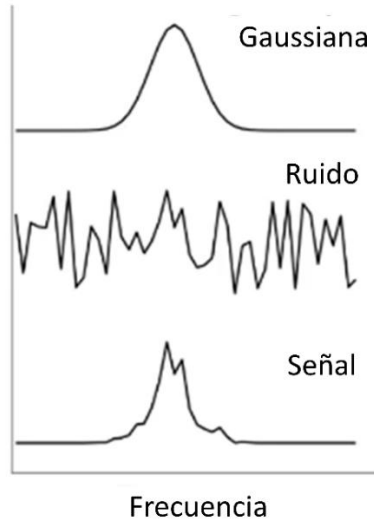


Figura 3.3 Generación de EEG sintético

Los parámetros iniciales definidos serán

- N : Números de puntos iniciales de la señal.
 - f_s : Frecuencia de muestreo
 - f_p : Frecuencia pico de la señal
 - $FWHM$: Ancho de banda de la señal
1. Generación de la función gaussiana en el dominio de la frecuencia. Sea la función gaussiana que en términos matemáticos se expresa como:

$$f(t) = e^{-\frac{(t-\mu)^2}{2\sigma^2}} \quad (3.1)$$

Donde:

- t es la variable de tiempo
 - μ es el tiempo central o media de la gaussiana, equivalente al peaktime.
 - σ es la desviación estándar equivalente a width
2. Vector de dominio de la frecuencia (ruido rosa). Se genera a partir de un vector de frecuencias de 0 a f_s , este será la densidad espectral de potencia del ruido rosa se define como:

$$f = \left[0, \frac{f_s}{N}, 2\frac{f_s}{N}, \dots, f_s \right] \quad (3.2)$$

El vector generado tiene N puntos.

3. Coeficientes de Fourier aleatorios. Para simular el ruido, se generan coeficientes de Fourier aleatorios. Cada coeficiente es un número complejo con una amplitud aleatoria y una fase aleatoria:

$$fc = A \cdot e^{j\Phi} \quad (3.3)$$

Donde:

- A es un vector de amplitudes aleatorias $A = \text{rand}(N)$, números aleatorios positivos.
- Φ es un vector de fases aleatorias $\Phi = 2\pi * \text{rand}(N)$.

Esto se puede expresar como:

$$fc = \text{rand}(N) * e^{j2\pi \text{rand}(N)} \quad (3.4)$$

4. Multiplicación por la gaussiana. Se realiza la multiplicación punto a punto de los coeficientes de Fourier por la gaussiana para obtener el espectro de amplitud:

$$fc = fc * fg \quad (3.5)$$

5. Transformada inversa de Fourier. Para obtener la señal en el dominio del tiempo, se realiza la transformada inversa de Fourier:

$$x(t) = 2 \cdot \text{Re}(\mathcal{F}^{-1}(fc)) \quad (3.6)$$

donde \mathcal{F}^{-1} es la transformada inversa de Fourier y $\text{Re}(\cdot)$ denota la parte real.

6. Señal sinusoidal. La señal sinusoidal se puede expresar matemáticamente como:

$$x(t) = \sin(2\pi ft + \phi) \quad (3.7)$$

Donde

- f es la frecuencia de la señal sinusoidal
- t es la variable de tiempo
- ϕ es la fase inicial de la señal que se produce manera aleatoria $2\pi \cdot \text{rand}(\quad)$

El resultado final de la señal EEG se expresa:

$$EEG = \sin(2\pi ft + \phi) * \text{Gaussiana} + A * fc * fg \quad (3.8)$$

- Envolvente Gaussiana: Modula la amplitud de la señal en el tiempo.
- Señal Seno: Onda seno se genera para la simulación.
- Ruido 1/f: Ruido rosa generado mediante la transformada inversa de Fourier.

Finalmente, el resultado de combinar la señal seno modulada con la envolvente gaussiana y el ruido es una señal EEG se puede ver en la Figura 3.3.




Figura 3.4 Simulación de datos EEG

3.3.3 Simulación de proyección de EEG en el cuero cabelludo

De acuerdo con (Cohen, 2022) se puede simular un EEG haciendo una proyección de dipolos simulando la actividad dipolar y proyección a través del campo de ganancia. En esta sección se analiza el algoritmo de simulación. Dada una selección de fuentes dipolares tal como se muestra en la Figura 3.5 las entradas para llevar a cabo el algoritmo de simulación de proyección de EEG en el cuero cabelludo.

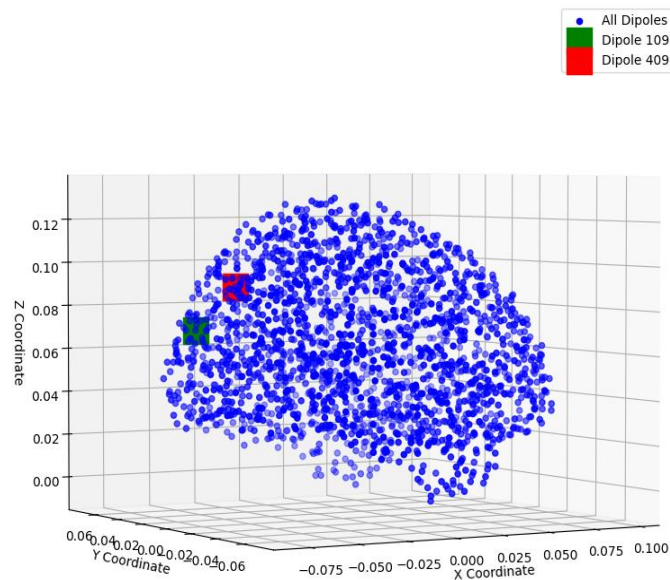


Figura 3.5 Selección de dipolos

La Figura 3.6 muestra un proceso de simulación de señales EEG a partir de la actividad de dipolos cerebrales. En la parte izquierda, se muestra un modelo cerebral con una distribución de dipolos, donde algunos dipolos específicos, localizados en la región occipital. Estos dipolos generan una señal EEG que se propaga desde la región occipital hacia la frontal. También se presenta una matriz de correlación que analiza los diferentes dipolos a la señal EEG generada, mostrando el coeficiente de correlación con una escala de colores que va de azul (baja correlación) a rojo (alta correlación). Por otro lado, se observa un mapa topográfico del cuero cabelludo que muestra la proyección de la actividad cerebral en la superficie, con una región de alta actividad destacada en color rojo, posiblemente en una zona central o frontal. También se incluye una señal EEG que representa la actividad proyectada en esa región específica. La señal EEG proyectada en un mapa topográfico del cuero cabelludo.

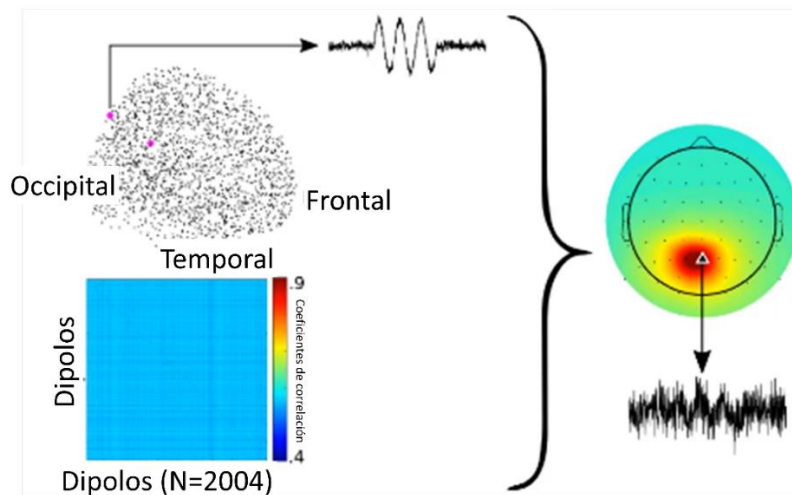


Figura 3.6 Proyección de dipolos

Dadas las siguientes definiciones y parámetros:

- $N_{ensayos}$: Numero de ensayos.
- N_{puntos} : Números de puntos por ensayo.
- $N_{dipolos}$: Números de fuentes dipolares.
- G : Matriz de ganancia, de tamaño $(N_{canales}, 1, N_{dipolos})$.
- $diploc1, diploc2$: Índices de los dipolos activos.
- $srate$: Frecuencia de muestreo del EEG.
- $gauss1, gauss2$: Envoltentes gaussianas para los dipolos 1 y 2.

A continuación, se muestran los pasos para generar el EEG para su proyección. Inicialización de la actividad dipolar. Para cada ensayo se genera actividad aleatoria para todos los dipolos:

$$dipact = 0.02 \cdot \mathcal{N}(0, 1), \text{dimensiones: } (N_{dipolos}, N_{puntos}) \quad (3.9)$$

Dada una selección de dipolos generar la señal para cada dipolo. Se genera una modulación de frecuencia para cada dipolo.

$$\begin{aligned} freqmod_1 &= 5 + 5 \\ &\cdot interp(linspace(1, 10, N_{puntos}), arange(1, 11), rand(10)) \end{aligned} \quad (3.10)$$

Se calcula la señal de frecuencia instantánea ($IFseñal_1$):

$$IFseñal_1 = \sin\left(2\pi \left(\frac{tiempo + cumsum(freqmod_1)}{srates}\right)\right) \quad (3.11)$$

La actividad del dipolo se modula por la envolvente gaussiana:

$$dipact[diploc1, :] = IFseñal_n \cdot gauss_n \quad (3.12)$$

Proyección al cuero cabelludo. La actividad dipolar se proyecta a los canales de EEG utilizando la matriz de ganancia G :

$$EEG_{datos}[:, :, ensayo_i] = G \times dipact \quad (3.13)$$

La señal proyectada tiene la forma:

$$EEG_{datos}: (N_{canales}, N_{puntos}, N_{ensayos}) \quad (3.14)$$




Figura 3.7 EEG generado a partir de la proyección de dipolos de la Figura 3.5

3.3.4 Generación de datos sintéticos

De acuerdo a los que nos plantea los autores (H. Zhang, Zhao, et al., 2021b) la Figura 3.4 muestra el proceso para añadir a una señal EEG artefactos de manera sintética.

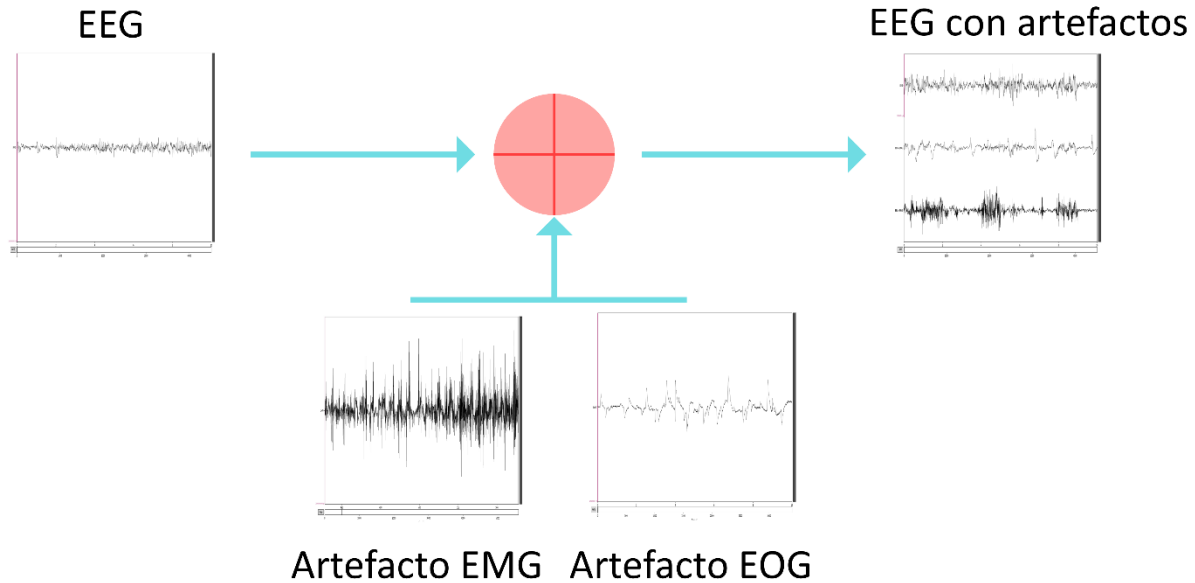


Figura 3.8 Diagrama general para añadir artefactos de manera sintética a la señal EEG

1. Dada la muestra $s(n)$ (ver Figura 3.9) de la EEG en el instante n , se calcula la potencia de la señal EEG.

$$\text{Potencia de la señal de EEG} = \frac{1}{N} \sum_{n=1}^N s(n)^2, \quad (3.15)$$




Figura 3.9 Señal EEG

donde N es el total de muestras.

2. La potencia de la señal está dada por la ecuación:

$$\text{Potencia de la señal de EEG (dB)} = 10 \log_{10}(\text{Potencia de la señal de EEG}). \quad (3.16)$$

3. Se calcula la potencia de las señales correspondientes a los artefactos (ver Figura 3.10) con la ecuación:

$$\text{Potencia de la señal de EEG} = \frac{\text{Potencia de la señal de EEG (dB)}}{10^{\frac{SNR}{10}}}, \quad (3.17)$$




Figura 3.10 Señales correspondientes a artefactos

donde SNR corresponde a la relación señal-ruido. Además, entre menor sea el SNR, la amplitud del artefacto es mayor que la señal EEG, y entre mayor sea la SNR, la amplitud del artefacto es menor que la de la señal de EEG.

4. Calcular la potencia del artefacto con la ecuación:

$$\text{Potencia del artefacto (dB)} = 10 \log_{10}(\text{Potencia de la señal del artefacto}). \quad (3.18)$$

5. Se calcula el nivel SNR para añadir a la señal EEG el artefacto.

$$\text{Señal EEG + Artefacto} = \sqrt{\text{Potencia de la señal del artefacto}} \frac{v(n)}{\sigma(v(n))}. \quad (3.19)$$

6. Finalmente se tiene la ecuación resultante que generar una señal EEG contaminada con artefactos.

$$\text{EEG + Artefacto} = \text{señal de EEG} + \text{señal del artefacto (EOG, EMG, etc)}. \quad (3.20)$$




Figura 3.11 Comparación de señales a) Señal EEG, b) Señal EEG+EOG y c) Señal EEG+EMG

3.3.5 Conjunto de datos

3.3.5.1 *Conjunto de datos de referencia para soluciones de aprendizaje profundo de extremo a extremo para la eliminación de ruido en EEG*

El corpus de datos Benchmark de (H. Zhang, Zhao, et al., 2021b) es un conjunto de datos adecuado para la investigación de eliminación de ruido en señales EEG basado en redes de aprendizaje profundo. Este conjunto de datos creó a partir de repositorios públicos en estudios previos, estos conjuntos de datos fueron (Brunner et al., 2007; Fatourechí et al., 2007; Kanoga et al., 2016; Schlögl et al., 2007) el cual proveen datos de EEG, EOG y EMG de varios repositorios de datos públicos. Para generar EEG limpio, EOG puro y EMG puro, primero se preprocesaron los datos y luego los segmentamos en segmentos de 2 segundos. Posteriormente, se reescala los segmentos para que tuvieran la misma varianza. Finalmente, cada segmento fue revisado visualmente por un experto para asegurar que estuvieran limpios y fueran utilizables. Se estableció una duración de los segmentos en 2 segundos de acuerdo con el conocimiento previo sobre señales EEG. Por un lado, un segmento de 2 segundos es lo suficientemente largo para recuperar las características temporales y espectrales del EEG, así como del EOG y EMG. el conjunto de datos incluyó a 52 participantes que realizaron tanto tareas de movimiento real como imaginario de la mano izquierda y derecha, con EEG de 64 canales grabados simultáneamente a una frecuencia de muestreo de 512 Hz. Para ambas tareas (real e imaginaria), un participante repitió un segmento de 2 segundos de línea base y 3 segundos de movimiento, con intervalos aleatorios de 4.1 a 4.8 segundos durante 20 minutos. Los datos fueron filtrados pasa banda entre 1 y 80 Hz, con un filtro notch a la frecuencia de la línea eléctrica, y luego se remuestreo a 256 Hz. Para obtener el EEG limpio como referencia, las señales EEG de 64 canales fueron procesadas con ICLabel, una herramienta para eliminar artefactos en EEG mediante composición de componentes independientes (ICA). Luego, las señales EEG puras fueron segmentadas en segmentos unidimensionales de 2 segundos. Cabe destacar que, para garantizar la universalidad de

este conjunto de datos, no se construyeron señales de EEG limpias con un número específico de canales debido a la diversidad de gorras EEG, sino que se construyó un conjunto de datos con señales EEG de un solo canal.

3.3.5.2 TUH EEG Artifact Corpus

El corpus TUH EEG Artifact Corpus de EEG del Hospital de la Universidad de Temple (TUEG) de (Obeid & Picone, 2016) fue desarrollado para apoyar investigaciones de vanguardia en la interpretación automática de EEG utilizando aprendizaje automático este tiene un total de 328 pacientes. El corpus consta de datos de señales EEG y de informes de EEG escritos por el neurólogo a cargo para cada sesión del paciente. Los datos de la señal se almacenan en formato de datos europeo (EDF) de código abierto, mientras que los informes se almacenan como archivos de texto plano. El encabezado de cada archivo EDF contiene información fundamental de metadatos sobre cada sesión del paciente, distribuida uniformemente en 24 campos que muestran información del paciente y el estado de la señal. Este corpus consiste completamente en datos clínicos recolectados desde 2002 hasta el presente en el Hospital de la Universidad de Temple (TUH). Los datos de señales EEG se recopilaron utilizando diversas generaciones de equipos EEG. La mayoría de los datos de 2002 a 2019 se recopilaron utilizando el equipo de grabación NicoletOne de Natus Medical Incorporated. Los datos en TUEG se recopilaron en diversas ubicaciones del hospital, incluyendo la unidad de cuidados intensivos (UCI), la unidad de monitoreo de epilepsia (EMU), la sala de emergencias y los servicios ambulatorios. Debido a que estas sesiones cubren toda la gama de EEG realizados en TUH, existe una amplia variedad de configuraciones y etiquetas de canales utilizadas para describir los datos de EEG. De hecho, hay más de 40 configuraciones de canales únicas contenidas en todo el corpus.

La disposición de electrodos más utilizada en los registros electroencefalográficos es el sistema Internacional 10/20. En este sistema, 21 electrodos en el cuero cabelludo se distribuyen uniformemente como se muestra en la Figura 3.12, con la distancia entre los electrodos siendo del 10% o 20% de la distancia total desde el nasion (parte frontal) hasta el inion (parte posterior). El sistema 10/20 utiliza cuatro puntos de referencia anatómicos para posicionar los electrodos: el punto entre la frente y la nariz (nasion), el punto más bajo en la parte posterior del cráneo (inion) y las áreas preauriculares anteriores a las orejas.




Figura 3.12 sistema internacional 10-20 y sus canales correspondientes en un EEG

Las anotaciones consisten en 10 tipos básicos de eventos:

- eyem (21): movimiento ocular
- chew (22): masticación
- shiv (23): escalofríos
- musc (24): artefacto muscular
- elec (30): una categoría general utilizada cuando ocurre cualquiera de tres tipos de artefactos: salto de electrodo, artefacto electrostático y artefacto de conductor.

A continuación Figura 3.13 en la se muestran el histograma de eventos correspondientes en el conjunto de datos de EEG.




Figura 3.13 Histograma de eventos de artefactos en EEG

3.4 Métricas de rendimiento para la eliminación de artefactos en señales EEG sintéticas

En esta sección, se menciona un resumen de las métricas comúnmente utilizadas para evaluar el rendimiento de los datos de EEG. De acuerdo con los autores como (Lopes et al., 2021; Mannan et al., 2018), la evaluación del rendimiento es un medio para verificar o comprobar la capacidad de un algoritmo para eliminar artefactos de los datos de EEG. Dado que la actividad neuronal subyacente en los datos de EEG registrados es desconocida, es una tarea difícil verificar completamente el rendimiento de un algoritmo. En la literatura, este problema se supera mediante el uso de datos de EEG simulados. En el EEG simulado, las señales limpias (señales de EEG registradas y analizadas cuidadosamente para asegurar que no tengan artefactos importantes) y los artefactos se mezclan utilizando tanto técnicas simples como complejas. Sin embargo, el EEG simulado no puede lograr una contaminación real como en el EEG registrado. Por lo tanto, un algoritmo también debería ser verificado utilizando datos experimentales de EEG.

Los autores como (Cohen, 2022; Lopes et al., 2021) mencionan que un algoritmo debería

pasar por un procedimiento de verificación en tres pasos.

1. Evaluación del algoritmo donde debería realizarse utilizando señales de EEG simuladas.
2. Luego, se deberían utilizar señales de EEG auto-registradas para verificar la efectividad del algoritmo.
3. Finalmente, deberían emplearse señales de EEG reales disponibles en bases de datos verificadas de EEG para este propósito.

Este procedimiento de verificación demostrará el rendimiento, la fiabilidad y la reproducibilidad reales de cualquier método de eliminación de artefactos. Una de las ventajas de usar una señal de EEG simulada es que la señal verdadera de EEG es conocida y puede usarse para evaluar el rendimiento de un algoritmo.

3.4.1 Error Cuadrático Medio

En el dominio temporal, el Error Cuadrático Medio (MSE) se puede utilizar para evaluar el rendimiento de un algoritmo calculando las diferencias entre la señal EEG verdadera ($EEG_{in}(i) \in \mathbb{R}^{1 \times N}$) y la señal EEG corregida ($EEG_{out}(i) \in \mathbb{R}^{1 \times N}$), el MSE se calcula de la siguiente manera:

$$MSE = \frac{1}{N} \sum_{i=1}^N (EEG_{in}(i) - EEG_{out}(i))^2 \quad (3.21)$$

donde:

- N : es el número total de muestras.
- $EEG_{in}(i)$: es el valor de la señal verdadera (ground truth) en el índice i .
- $EEG_{out}(i)$: es el valor de la señal corregida en el índice i .

3.4.2 Error Cuadrático Medio de la Raíz (RMSE)

El Error Cuadrático Medio de la Raíz (RMSE) es otra métrica comúnmente utilizada para cuantificar la cantidad de información preservada por un algoritmo. El RMSE proporciona una medida de la magnitud de los errores entre la señal estimada y la señal verdadera, expresada en las mismas unidades que los datos originales. Se calcula de la siguiente manera:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (EEG_{in}(i) - EEG_{out}(i))^2} \quad (3.22)$$

donde:

- N : es el número total de muestras.
- $EEG_{in}(i)$: es el valor de la señal verdadera (ground truth) en el índice i .
- $EEG_{out}(i)$: es el valor de la señal corregida en el índice i .

3.4.3 Error Cuadrático Medio Normalizado (NMSE)

El Error Cuadrático Medio Normalizado (NMSE) es otra métrica utilizada en estudios de eliminación de artefactos en EEG para evaluar el rendimiento de los algoritmos. El NMSE proporciona una medida relativa del error, normalizando el Error Cuadrático Medio con respecto a la energía de la señal verdadera. Se calcula de la siguiente manera:

$$NMSE = \frac{\sum_{i=0}^N (EEG_{out}(i) - EEG_{in}(i))^2}{\sum_{i=0}^N (EEG_{in}(i))^2} \quad (3.23)$$

donde:

- N : es el número total de muestras.
- $EEG_{in}(i)$: es el valor de la señal verdadera (ground truth) en el índice i .
- $EEG_{out}(i)$: es el valor de la señal corregida en el índice i .

3.4.4 Error relativo

El Error Relativo (RE) es otra métrica en el dominio temporal que ha sido utilizada en varios estudios para evaluar la efectividad de los algoritmos en la eliminación de artefactos en datos EEG. El RE proporciona una medida de la discrepancia entre la señal corregida y la señal verdadera, normalizada por la magnitud de la señal verdadera. Se calcula de la siguiente manera:

$$RE = \frac{\|EEG_{out} - EEG_{in}\|}{\|EEG_{in}\|} \quad (3.24)$$

donde:

- N : es el número total de muestras.
- EEG_{in} : es la señal verdadera (ground truth).
- EEG_{out} : es la señal corregida.

3.4.5 Relación señal a artefacto

La relación señal a artefacto (Signal-to-artifact ratio, SAR) es la métrica comúnmente utilizada para evaluar las mejoras en la señal EEG corregida en comparación con la señal EEG contaminada. La relación señal a artefacto para señales EEG contaminadas $EEG_{con}(i) \in \mathbb{R}^{1 \times N}$ se calcula como:

$$SAR_B = \frac{\frac{1}{N} \sum_{n=1}^N |EEG_{in}|^2}{\frac{1}{N} \sum_{n=1}^N |EEG_{con} - EEG_{in}|^2} \quad (3.25)$$

donde SAR_B es la relación señal a artefacto antes de la eliminación de artefactos, y $EEG_{con} = EEG_{in} + noise$. La relación señal a artefacto para el EEG corregido se puede calcular como:

$$SAR_A = \frac{\frac{1}{N} \sum_{n=1}^N |EEG_{in}|^2}{\frac{1}{N} \sum_{n=1}^N |EEG_{out} - EEG_{in}|^2} \quad (3.26)$$

donde SAR_A es la relación señal a artefacto después de la eliminación de artefactos. Un algoritmo efectivo de eliminación de artefactos eliminará todos los artefactos y tendrá valores de SAR_A más altos; consecuentemente, $SAR_A > SAR_B$. La ganancia en la relación señal a artefacto (γ) se puede calcular como:

$$\gamma = 10 \log \left(\frac{SAR_A}{SAR_B} \right) \quad (3.27)$$

El valor de γ será positivo si la relación señal a artefacto mejora, negativo si disminuye, y cero si no hay mejora.

3.4.6 Información mutua

La cantidad de información mutua (MI) entre el EEG corregido por un algoritmo de eliminación de artefactos y el EEG verdadero puede calcularse para analizar la efectividad de un algoritmo en la extracción de señales EEG verdaderas a partir de señales EEG contaminadas. Matemáticamente, la MI se puede calcular como:

$$MI = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(a, b) \log \frac{f(a, b)}{f(a)f(b)} da db \quad (3.28)$$

donde $f(a, b)$ es la función de densidad de probabilidad conjunta (pdf conjunta) y $f(a)$ y $f(b)$ son las funciones de densidad de probabilidad marginales (pdf marginales). Las señales EEG corregidas y EEG verdaderas están estrechamente relacionadas si y solo si la información mutua (MI) entre ellas es alta.

3.4.7 Error Absoluto Medio

En el dominio de la frecuencia, el error absoluto medio (MAE), que se puede utilizar como una métrica de evaluación para medir la distorsión en diferentes bandas de frecuencia, se puede calcular como:

$$MAE = |P_{inEEG} - P_{outEEG}| \quad (3.29)$$

donde p denota la densidad espectral de potencia.

3.4.8 Coeficiente de Correlación de Pearson

El Coeficiente de Correlación de Pearson (PCC) es una métrica utilizada para medir la correlación lineal entre los segmentos de señal sin ruido y los segmentos objetivo. Este coeficiente indica qué tan bien se alinean los valores de la señal sin ruido con los de la señal original, y se calcula de la siguiente manera:

$$PCC(x, y) = \frac{Covarianza(x, y)}{\sigma_x \sigma_y} \quad (3.30)$$

El *PCC* varía entre -1 y 1, 1 indica una fuerte correlación lineal positiva entre la señal sin ruido y la señal verdadera, un valor cercano a 0 indica que no hay correlación lineal entre las señales y un valor cercano a -1 indica una fuerte correlación lineal negativa.

3.1 Métricas de rendimiento para la eliminación de artefactos en señales EEG reales

De acuerdo con (Mannan et al., 2018) dado que el EEG verdadero subyacente es desconocido en señales EEG experimentales, no existe un consenso entre los investigadores sobre la validación de las técnicas de eliminación de artefactos cuando se aplican a señales EEG reales. Sin embargo, varios investigadores han propuesto esquemas para la verificación y validación de algoritmos. El autor menciona que se han desarrollado esquema como el basado en la correlación entre el EEG reconstruido y el canal de referencia EOG, así como en la consistencia de ERP asociada con movimientos oculares en los canales EOG. Sin embargo, esta validación tiene dos limitaciones: su dependencia del EOG registrado y el uso de toda una época para la validación de desviación estándar, que incluye datos irrelevantes. Por otro lado, también se ha abordado para los artefactos musculares. Se propuso evaluar si un método elimina/reduce exitosamente los artefactos (su sensibilidad) y si preserva las señales neuronales (su especificidad) usando una región de interés. Finalmente, se ha recurrido a expertos en el análisis de señales EEG para inspeccionar visualmente los resultados de los algoritmos de eliminación de artefactos mediante la revisión de factores como la serie temporal y el espectro de frecuencia antes y después del proceso de eliminación. La limitación de esta validación es que depende en gran medida de la experiencia del investigador para indicar si el algoritmo de eliminación de artefactos mejoró o disminuyó la calidad de la señal EEG.

3.2 Desarrollo del modelo de aprendizaje profundo

3.2.1 Diseño de la arquitectura del modelo

3.2.2 Configuración de hiperparámetros

3.2.3 Técnicas de regularización y optimización

3.3 Implementación de la Adaptación de Dominio

3.3.1 Definición de dominios fuente y objetivo.

3.3.2 Estrategias de alineación de distribuciones

3.4 Procedimiento de Entrenamiento y Validación

3.4.1 División de datos

3.4.2 Métricas de rendimiento

3.5 Herramientas y Entornos de Desarrollo

3.5.1 Software y librerías utilizadas

3.5.2 Recursos computacionales

Capítulo 4 Resultados

4.1 Análisis de Rendimiento del Modelo

4.1.1 Precisión en eliminación de artefactos

4.1.2 Comparación con técnicas tradicionales

4.2 Evaluación de la Adaptación de Dominio

4.2.1 Rendimiento en dominios no vistos

4.2.2 Robustez del modelo ante variaciones

4.3 Visualización de Resultados

4.3.1 Señales antes y después del procesamiento

4.3.2 Mapas de activación y interpretabilidad del modelo

4.4 Estudios de Caso

4.4.1 Aplicaciones prácticas en entornos clínicos

Capítulo 5 Discusión

5.1 Interpretación de los Resultados

5.1.1 Implicaciones de los hallazgos

5.2 Ventajas del Enfoque Propuesto

5.2.1 Mejoras en precisión y generalización

5.3 Limitaciones del Estudio

5.3.1 Restricciones de datos y modelo

5.4 Sugerencias para Trabajos Futuros

5.4.1 Extensiones del modelo

5.4.2 Aplicaciones en otras señales biomédicas

Capítulo 6 Conclusiones

6.1 Resumen de Contribuciones

6.1.1 Logros alcanzados respecto a los objetivos

6.2 Impacto en el Campo de Estudio

6.2.1 Avances en procesamiento de señales EEG.

6.3 Recomendaciones

Capítulo 7 Anexos

7.1 Detalles Técnicos Adicionales

7.2 Publicaciones Derivadas

Referencias

- [1]. Ahmadizadeh, M., & Hemmati, O. (n.d.). *An Introduction to HILBERT-HUANG TRANSFORM and EMPIRICAL MODE DECOMPOSITION (HHT-EMD) Advanced Structural Dynamics (CE 20162)*.
- [2]. Al Imran, I., & Rabbani, M. (2022). Comparison of Deep Learning & Adaptive Algorithm Performance for De-Noising EEG. *Journal of Physics: Conference Series*, 2325(1). <https://doi.org/10.1088/1742-6596/2325/1/012038>
- [3]. Alharbi, N. (2018). A novel approach for noise removal and distinction of EEG recordings. *Biomedical Signal Processing and Control*, 39, 23–33. <https://doi.org/https://doi.org/10.1016/j.bspc.2017.07.011>
- [4]. Alyasseri, Z. A. A., Khader, A. T., Al-Betar, M. A., Abasi, A. K., & Makhadmeh, S. N. (2020). EEG Signals Denoising Using Optimal Wavelet Transform Hybridized with Efficient Metaheuristic Methods. *IEEE Access*, 8, 10584–10605. <https://doi.org/10.1109/ACCESS.2019.2962658>
- [5]. An, Y., Lam, H. K., & Ling, S. H. (2022). Auto-Denoising for EEG Signals Using Generative Adversarial Network. *Sensors*, 22(5). <https://doi.org/10.3390/s22051750>
- [6]. Anantha Rufus, H. N. (2024). Advanced Ocular Artifact Removal In EEG For Enhanced Schizophrenia Diagnosis Using Wavelet Shrinkage And LSTM Deep Learning Techniques. In *Nanotechnology Perceptions* (Vol. 20, Issue S11). <https://orcid.org/0000-0003-0965-2796>
- [7]. Anas Fouad Ahmed. (2022). A quick survey of EEG signal noise removal methods. *Global Journal of Engineering and Technology Advances*, 11(3), 098–104. <https://doi.org/10.30574/gjeta.2022.11.3.0100>
- [8]. Aphimeteetamrong, D., Thiennviboon, P., Intarawichian, S., Sungkarat, W., & Laothamatas, J. (2024). Apnea/Hypopnea Detection Using Modified YOLOv8n Model on Non-EEG Signals. *2024 21st International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON)*, 1–6. <https://doi.org/10.1109/ECTI-CON60892.2024.10594840>
- [9]. Bitbrain. (2020). *All about EEG artifacts and filtering tools*. <https://www.bitbrain.com/blog/eeg-artifacts>
- [10]. Brophy, E., Redmond, P., Fleury, A., De Vos, M., Boylan, G., & Ward, T. (2022). Denoising EEG Signals for Real-World BCI Applications Using GANs. *Frontiers in Neuroergonomics*, 2. <https://doi.org/10.3389/fnrgo.2021.805573>
- [11]. Brunner, C., Naeem, M., Leeb, R., Graimann, B., & Pfurtscheller, G. (2007). Spatial filtering and selection of optimized components in four class motor imagery EEG data using independent components analysis. *Pattern Recognition Letters*, 28(8), 957–964. <https://doi.org/https://doi.org/10.1016/j.patrec.2007.01.002>
- [12]. Cao, J., Fang, Y., Cui, X., Zheng, R., Jiang, T., & Gao, F. (2024). Synchronized Video and EEG Based Childhood Epilepsy Seizure Detection. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 1–12. <https://doi.org/10.1109/TETCI.2024.3372387>
- [13]. Chambon, S., Thorey, V., Arnal, P. J., Mignot, E., & Gramfort, A. (2019). DOSED: A deep learning approach to detect multiple sleep micro-events in EEG signal. *Journal of Neuroscience Methods*, 321, 64–78. <https://doi.org/10.1016/j.jneumeth.2019.03.017>
- [14]. Chen, J., Min, C., Wang, C., Tang, Z., Liu, Y., & Hu, X. (2022). Electroencephalograph-Based Emotion Recognition Using Brain Connectivity Feature and Domain Adaptive Residual Convolution Model. *Frontiers in Neuroscience*, 16. <https://doi.org/10.3389/fnins.2022.878146>
- [15]. Chen, J., Pi, D., Jiang, X., & Chen, Y. (2021). *Cross-Subject Domain Adaptation for Classifying Working Memory Load with Multi-Frame EEG Images*.

- <http://arxiv.org/abs/2106.06769>
- [16]. Cohen, M. X. (2022). A tutorial on generalized eigendecomposition for denoising, contrast enhancement, and dimension reduction in multichannel electrophysiology. *NeuroImage*, 247. <https://doi.org/10.1016/j.neuroimage.2021.118809>
 - [17]. Creswell, A., White, T., Dumoulin, V., Arulkumaran, K., Sengupta, B., & Bharath, A. A. (2018). Generative Adversarial Networks: An Overview. *IEEE Signal Processing Magazine*, 35(1), 53–65. <https://doi.org/10.1109/msp.2017.2765202>
 - [18]. Cui, Y., Xie, S., Xie, X., Zhang, X., & Liu, X. (2022). Dynamic probability integration for electroencephalography-based rapid serial visual presentation performance enhancement: Application in nighttime vehicle detection. *Frontiers in Computational Neuroscience*, 16. <https://doi.org/10.3389/fncom.2022.1006361>
 - [19]. Elshekhdri, I. H., Mohamedamien, M. B., & Fragoon, A. (2023). WAVELET TRANSFORMS FOR EEG SIGNAL DENOISING AND DECOMPOSITION. In *Int. J. Adv. Sig. Img. Sci* (Vol. 9, Issue 2).
 - [20]. Fatourech, M., Bashashati, A., Ward, R. K., & Birch, G. E. (2007). EMG and EOG artifacts in brain computer interface systems: A survey. *Clinical Neurophysiology*, 118(3), 480–494. <https://doi.org/10.1016/j.clinph.2006.10.019>
 - [21]. Gajbhiye, P., Mingchinda, N., Chen, W., Mukhopadhyay, S. C., Wilaprasitporn, T., & Tripathy, R. K. (2021). Wavelet Domain Optimized Savitzky-Golay Filter for the Removal of Motion Artifacts from EEG Recordings. *IEEE Transactions on Instrumentation and Measurement*, 70. <https://doi.org/10.1109/TIM.2020.3041099>
 - [22]. Giulia Cisotto, L. S. (2022). *Attention-based EEG classification*.
 - [23]. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2020). Generative Adversarial Networks. *Commun. ACM*, 63(11), 139–144. <https://doi.org/10.1145/3422622>
 - [24]. Goyal, D., & Pabla, B. S. (2015). Condition based maintenance of machine tools—A review. *CIRP Journal of Manufacturing Science and Technology*, 10, 24–35. <https://doi.org/10.1016/j.cirpj.2015.05.004>
 - [25]. Grobelaar, M., Phadikar, S., Ghaderpour, E., Struck, A. F., Sinha, N., Ghosh, R., & Ahmed, M. Z. I. (2022). A Survey on Denoising Techniques of Electroencephalogram Signals Using Wavelet Transform. In *Signals* (Vol. 3, Issue 3, pp. 577–586). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/signals3030035>
 - [26]. Hemanth, K. G. (2020). *Module 2 - Bioelectric Signals and Electrodes*.
 - [27]. Huang, N. E. (n.d.). *CHAPTER 1 INTRODUCTION TO THE HILBERT-HUANG TRANSFORM AND ITS RELATED MATHEMATICAL PROBLEMS*.
 - [28]. Jackson, A. F., & Bolger, D. J. (2014). The Neurophysiological Bases of EEG and EEG Measurement: A Review for the Rest of Us. In *Psychophysiology* (Vol. 51, Issue 11, pp. 1061–1071). Blackwell Publishing Inc. <https://doi.org/10.1111/psyp.12283>
 - [29]. Jake. (2023). Introduction to Wavelet Transform using Python. *Scicoding*. <https://www.scicoding.com/introduction-to-wavelet-transform-using-python/>
 - [30]. Jiang, X., Bian, G. Bin, & Tian, Z. (2019). Removal of artifacts from EEG signals: A review. In *Sensors (Switzerland)* (Vol. 19, Issue 5). MDPI AG. <https://doi.org/10.3390/s19050987>
 - [31]. Kanoga, S., Nakanishi, M., & Mitsukura, Y. (2016). Assessing the effects of voluntary and involuntary eyeblinks in independent components of electroencephalogram. *Neurocomputing*, 193, 20–32. <https://doi.org/10.1016/j.neucom.2016.01.057>
 - [32]. Kaur, C., Bisht, A., Singh, P., & Joshi, G. (2021). EEG Signal denoising using hybrid approach of Variational Mode Decomposition and wavelets for depression. *Biomedical Signal Processing and Control*, 65. <https://doi.org/10.1016/j.bspc.2020.102337>
 - [33]. Kawala-Sterniuk, A., Browarska, N., Al-Bakri, A., Pelc, M., Zygarlicki, J., Sidikova, M., Martinek, R., & Gorzelanczyk, E. J. (2021). *brain sciences Summary of over Fifty Years with*

- Brain-Computer Interfaces-A Review*. <https://doi.org/10.3390/brainsci>
- [34]. Lan, Z., Sourina, O., Wang, L., Scherer, R., & Muller-Putz, G. R. (2019). Domain Adaptation Techniques for EEG-Based Emotion Recognition: A Comparative Study on Two Public Datasets. *IEEE Transactions on Cognitive and Developmental Systems*, 11(1), 85–94. <https://doi.org/10.1109/TCDS.2018.2826840>
 - [35]. Lin, N., Gao, W., Li, L., Chen, J., Liang, Z., Yuan, G., Sun, H., Liu, Q., Chen, J., Jin, L., Huang, Y., Zhou, X., Zhang, S., Hu, P., Dai, C., He, H., Dong, Y., Cui, L., & Lu, Q. (2024). vEpiNet: A multimodal interictal epileptiform discharge detection method based on video and electroencephalogram data. *Neural Networks*, 175. <https://doi.org/10.1016/j.neunet.2024.106319>
 - [36]. Liu, T., & Wu, Z. (2024). Epileptic Spike Wave Detection Method Based on YOLOv7-tiny. *Proceedings of the 3rd International Conference on Computer, Artificial Intelligence and Control Engineering*, 750–755. <https://doi.org/10.1145/3672758.3672883>
 - [37]. Lopes, F., Leal, A., Medeiros, J., Pinto, M. F., Dourado, A., Dumpelmann, M., & Teixeira, C. (2021). Automatic Electroencephalogram Artifact Removal Using Deep Convolutional Neural Networks. *IEEE Access*, 9, 149955–149970. <https://doi.org/10.1109/ACCESS.2021.3125728>
 - [38]. Madhale Jadav, G., Lerga, J., & Štajduhar, I. (2020). Adaptive filtering and analysis of EEG signals in the time-frequency domain based on the local entropy. *Eurasip Journal on Advances in Signal Processing*, 2020(1). <https://doi.org/10.1186/s13634-020-00667-6>
 - [39]. Mannan, M. M. N., Kamran, M. A., & Jeong, M. Y. (2018). Identification and removal of physiological artifacts from electroencephalogram signals: A review. *IEEE Access*, 6, 30630–30652. <https://doi.org/10.1109/ACCESS.2018.2842082>
 - [40]. Mashhadi, N., Khuzani, A. Z., Heidari, M., & Khaledyan, D. (2020, October 29). Deep learning denoising for EOG artifacts removal from EEG signals. *2020 IEEE Global Humanitarian Technology Conference, GHTC 2020*. <https://doi.org/10.1109/GHTC46280.2020.9342884>
 - [41]. Mateo, J., Torres, A. M., García, M. A., & Santos, J. L. (2016). Noise removal in electroencephalogram signals using an artificial neural network based on the simultaneous perturbation method. *Neural Computing and Applications*, 27(7), 1941–1957. <https://doi.org/10.1007/s00521-015-1988-7>
 - [42]. Niedermeyer, E. (2017). *Niedermeyer's Electroencephalography* (D. L. Schomer & F. H. Lopes da Silva, Eds.; Vol. 1). Oxford University Press. <https://doi.org/10.1093/med/9780190228484.001.0001>
 - [43]. Obeid, I., & Picone, J. (2016). The temple university hospital EEG data corpus. *Frontiers in Neuroscience*, 10(MAY). <https://doi.org/10.3389/fnins.2016.00196>
 - [44]. Phadikar, S., Sinha, N., & Ghosh, R. (2020). Automatic EEG eyeblink artefact identification and removal technique using independent component analysis in combination with support vector machines and denoising autoencoder. *IET Signal Processing*, 14(6), 396–405. <https://doi.org/10.1049/iet-spr.2020.0025>
 - [45]. Pise, A. W., & Rege, P. P. (2021, April 2). Comparative Analysis of Various Filtering Techniques for Denoising EEG Signals. *2021 6th International Conference for Convergence in Technology, I2CT 2021*. <https://doi.org/10.1109/I2CT51068.2021.9417984>
 - [46]. Qiu, Y., Zhou, W., Yu, N., & Du, P. (2018). Denoising Sparse Autoencoder-Based Ictal EEG Classification. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 26(9), 1717–1726. <https://doi.org/10.1109/TNSRE.2018.2864306>
 - [47]. Quintero-Rincón, A., Giano, C. D. ', & Batatia, H. (2021). *Chapter 11. Artefacts Detection in EEG Signals Artefacts Detection in EEG Signals*.
 - [48]. Saini, M., Satija, U., & Upadhayay, M. D. (2020). Wavelet Based Waveform Distortion Measures for Assessment of Denoised EEG Quality with Reference to Noise-Free EEG Signal. *IEEE Signal Processing Letters*, 27, 1260–1264.

- <https://doi.org/10.1109/LSP.2020.3006417>
- [49]. Sanei, S., & Chambers, J. A. (2007). *EEG Signal Processing*.
 - [50]. Schlögl, A., Keinrath, C., Zimmermann, D., Scherer, R., Leeb, R., & Pfurtscheller, G. (2007). A fully automated correction method of EOG artifacts in EEG recordings. *Clinical Neurophysiology*, 118(1), 98–104. <https://doi.org/https://doi.org/10.1016/j.clinph.2006.09.003>
 - [51]. Shahbakhti, M. (2020). *Efficient Methods for Electroencephalogram Signal Denoising Master's Final Degree Project*.
 - [52]. Shen, M., Zou, B., Li, X., Zheng, Y., Li, L., & Zhang, L. (2021). Multi-source signal alignment and efficient multi-dimensional feature classification in the application of EEG-based subject-independent drowsiness detection. *Biomedical Signal Processing and Control*, 70. <https://doi.org/10.1016/j.bspc.2021.103023>
 - [53]. Tandle, A., Bhakti Vedanta Marg Vile Parle, S., -, M., Jog Professor Electronics, N., & Chheta, M. (2016). Classification of Artefacts in EEG Signal Recordings and EOG Artefact Removal using EOG Subtraction. In *Communications on Applied Electronics (CAE)* (Vol. 4, Issue 1). www.caeaccess.org
 - [54]. Tang, X., & Zhang, X. (2020). Conditional adversarial domain adaptation neural network for motor imagery EEG decoding. *Entropy*, 22(1), 96. <https://doi.org/10.3390/e22010096>
 - [55]. Taran, S., & Bajaj, V. (2019). Emotion recognition from single-channel EEG signals using a two-stage correlation and instantaneous frequency-based filtering method. *Computer Methods and Programs in Biomedicine*, 173, 157–165. <https://doi.org/10.1016/j.cmpb.2019.03.015>
 - [56]. Walters-Williams, J., & Li, Y. (2011). A New Approach to Denoising EEG Signals-Merger of Translation Invariant Wavelet and ICA. In *International Journal of Biometrics and Bioinformatics* (Issue 5).
 - [57]. Wang, K., Gou, C., Duan, Y., Lin, Y., Zheng, X., & Wang, F.-Y. (2017). Generative adversarial networks: introduction and outlook. *IEEE/CAA Journal of Automatica Sinica*, 4(4), 588–598. <https://doi.org/10.1109/JAS.2017.7510583>
 - [58]. Wilroth, J., Bernhardsson, B., Heskebeck, F., Skoglund, M. A., Bergeling, C., & Alickovic, E. (2023). Improving EEG-based decoding of the locus of auditory attention through domain adaptation. *Journal of Neural Engineering*, 20(6). <https://doi.org/10.1088/1741-2552/ad0e7b>
 - [59]. Wu, W., Ma, L., Lian, B., Cai, W., & Zhao, X. (2022). Few-Electrode EEG from the Wearable Devices Using Domain Adaptation for Depression Detection. *Biosensors*, 12(12). <https://doi.org/10.3390/bios12121087>
 - [60]. Yadav, D., Yadav, S., & Veer, K. (2020). A comprehensive assessment of Brain Computer Interfaces: Recent trends and challenges. In *Journal of Neuroscience Methods* (Vol. 346). Elsevier B.V. <https://doi.org/10.1016/j.jneumeth.2020.108918>
 - [61]. Yao, Y., Plested, J., Gedeon, T., Liu, Y., & Wang, Z. (n.d.). *Improved Techniques for Building EEG Feature Filters*. <http://www.ieee.org/publications>
 - [62]. Yu, J., Li, C., Lou, K., Wei, C., & Liu, Q. (2022). Embedding decomposition for artifacts removal in EEG signals. *Journal of Neural Engineering*, 19(2). <https://doi.org/10.1088/1741-2552/ac63eb>
 - [63]. Zhang, H., Wei, C., Zhao, M., Liu, Q., & Wu, H. (2021). A novel convolutional neural network model to remove muscle artifacts from eeg. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings, 2021-June*, 1265–1269. <https://doi.org/10.1109/ICASSP39728.2021.9414228>
 - [64]. Zhang, H., Zhao, M., Wei, C., Mantini, D., Li, Z., & Liu, Q. (2021a). EEGdenoiseNet: A benchmark dataset for deep learning solutions of EEG denoising. *Journal of Neural Engineering*, 18(5). <https://doi.org/10.1088/1741-2552/ac2bf8>
 - [65]. Zhang, H., Zhao, M., Wei, C., Mantini, D., Li, Z., & Liu, Q. (2021b). EEGdenoiseNet: A benchmark dataset for deep learning solutions of EEG denoising. *Journal of Neural*

- Engineering*, 18(5). <https://doi.org/10.1088/1741-2552/ac2bf8>
- [66]. Zhang, Z., Yu, X., Rong, X., & Iwata, M. (2022b). A Novel Multimodule Neural Network for EEG Denoising. *IEEE Access*, 10, 49528–49541. <https://doi.org/10.1109/ACCESS.2022.3173261>

Anexos